Utilisation avancée d'Unix et Programmation Shell

ENSIMAG

2021-2022

Outline

Bienvenue dans le cours « Unix Avancé »

- Contenu :
  - Quelques aspects intéressants d'Unix qui vous facilitent la vie
  - Fondamentaux et programmation avec le shell unix
  - Git, le gestionnaire de version
- Utilité :
  - Gagner du temps au quotidien en automatisant des tâches répétitives et apprendre un langage de programmation largement utilisé pour manipuler processus et fichiers (au moins dans le projet GL en 2A)
  - Apprendre à sauvegarder et partager efficacement son code
- 5 Séances de 1h30, majoritairement en salle machine :
  1. Unix : sa vie, son œuvre (la suite de ces transparents)
  2. TP Unix pas à pas
  3. Git (gestionnaire de version) pas-à-pas ou Git avancé (branches, bases de l'implémentation de l'outil, historique).
  4. Les variables d'environnement
  5. Les expressions régulières

Jeu de piste, partie 2

- Départ en bas de page : `http://ensiwiki.ensimag.fr/index.php/TP_Unix_-_Jeu_de_piste`
- Aborde des notions un peu avancées (Unix, réseau, ...), mais largement faisable !
- Pas de note, mais amusez-vous bien ;-)

1960s Multics (Multiplexed Information and Computing Service),
1969 Ken Thompson et Dennis Ritchie écrivent la première version d'Unix, en assembleur.

"something as complex as an operating system, which must deal with time-critical events, had to be written exclusively in assembly language"

Ken (assis), Dennis (debout) devant un PDP-11, 1972

1973 Ré-écriture d'Unix en langage C
1988 Norme POSIX = « Portable Operating System Interface » for Unix
1991 Linux 0.0.1, écrit par Linus Torvalds à 21 ans
⇒ vers l'arrivée d'Unix sur les ordinateurs personnels

Unix aujourd'hui

- Mac OS X est un Unix
- GNU/Linux est un Unix (pas certifié officiellement)
- Les 500 plus gros ordinateurs de la planète fonctionnent sous Unix (juin 2021 : 100 % sont sous Linux, en 44 variantes)
- Et dans les smartphones ?
  - Android > 80 % du marché est basé sur Linux
  - iOS > 15 % du marché est basé sur un Unix
- Dans les box internet aussi, c'est du Linux
- ...

Composants d'un système complet

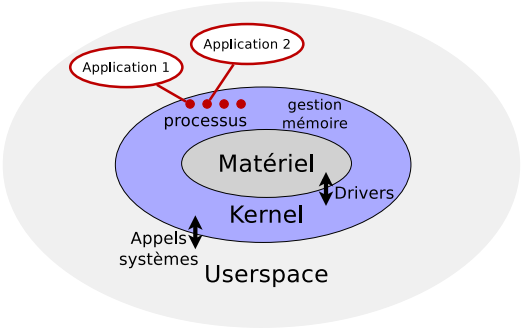

Composants d'un système complet

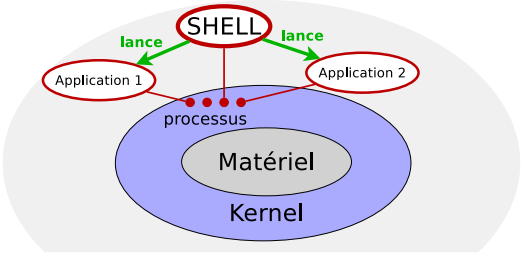

Shell : **application interactive qui permet d'en lancer d'autres !**

Exemples : explorateur de fichiers Windows (Shell graphique), interprète de commandes Unix, ...

Principe du shell interactif

- Pseudo-algorithme :

```
while True:
    commande = lire_commande()      # (1)
    commande = expanser(commande)   # (2)
    executer(commande)              # (3)
```

- Exemple : `$ ls -l *.c`
- Entré dans un éditeur de ligne (1)
  - Saisie de caractères
  - Navigation dans la ligne (fleches gauche/droite)
  - Historique
  - ...
- Expansé en `ls -l toto.c autre-fichier.c` (2)
  - « wildcards » comme `*`, `[abc]`, `?` expansés à partir des noms de fichiers (appelé aussi expansion des « glob »),
  - Variables comme `$toto` remplacées par leur valeur.
  - ...
- Exécute la commande `ls` avec les arguments `-l`, `toto.c`, et `autre-fichier.c`. (3)
  - Fait appel au système d'exploitation
  - (Rendez-vous en 2A pour les détails)

Éditeur de ligne du shell

- Completion avec TAB
  - Moins de choses à taper
  - Moins de fautes de frappes
  - C'est la fonctionnalité qui fait que le shell est souvent plus efficace qu'une interface graphique
- Historique
  - Flèches haut/bas
  - `!` (bang) : `!!`, `!n`, `!string`, `!?string`, ...
- Recherche en arrière
  - `C-r` (Control+r) pour rechercher une commande dans l'historique
- Complétion avancée
  - `Alt-g` affichage de l'expansion « glob »
  - `C-x*` expansion « glob » manuelle
- et bien d'autres raccourcis... `bind -P` donne une liste

Substitutions, expansions : les wildcards

- Wildcards : remplacements de motifs par rapport aux fichiers existants
  - `*` : n'importe quelle sous-chaine (sauf un point en début de nom de fichier),
  - `?` : n'importe quel caractère (sauf un point en début de nom de fichier),
  - `[abc]` un a, un b ou un c,
  - `[!abc]` (ou `[^abc]`, non-POSIX) n'importe quel caractère sauf un a, un b, ou un c.
  - `debut{un,deux,trois}fin` expansé en « `debutunfin` », « `debutdeuxfin` », « `debuttroisfin` » (sans rapport avec les fichiers existants) (marche en bash, non POSIX).
- Exemple : `rm *.od[tp]` ⇒ supprime tous les fichiers `.odt` (fichier OpenDocument Text) et `.odp` (fichier OpenDocument Presentation).

les wildcards : exercices

- Exercice : Comment faire pour reconnaître tous les fichiers et dossiers dans le répertoire courant (sauf . et ..) ?
  ⇒ `*  .[^.]*  ..?*`
  - Les fichiers ne commençant pas par `.`
  - Ceux commençant par `.` suivis d'autre chose qu'un point
  - Ceux commençant par `..`, mais suivis d'autre chose
- Exercice : Comment renommer un fichier `un-fichier-avec-un-nom-long.txt` en `un-fichier-avec-un-nom-long.txt.bak` sans taper deux fois le nom du fichier ?
  ⇒ `mv un-fichier-avec-un-nom-long.txt{,.bak}`
  - `{,.bak}` avec la chaîne vide en première position
  - Expansé en `mv un-fichier-avec-un-nom-long.txt un-fichier-avec-un-nom-long.txt.bak`

Substitutions, expansions : les variables

- Principe
  - Définition (globale) :
    - `x=toto`
  - Utilisation :
    - `ls $x`
    - `ls ${x}` (équivalent, mais `${x}y` est différent de `$xy` !)
- Précautions ...

```
x="fichier avec espaces.txt"
rm ${x}
```

  ⇒ essaye de supprimer les fichiers « `fichier` », « `avec` », et « `espaces.txt` »
- ⇒ c'est plus compliqué que ça n'en a l'air ...

L'interprétation des blancs, ou « Découpage »

- En fait, l'interprétation de la ligne de commande est un peu plus compliquée :
  - Substitution des variables
  - Interprétation des blancs
  - Expansions des wildcards
- Interprétation des blancs = découpage de la ligne de commande (commande, argument 1, argument 2, ...)
- Exemple : `ls -l toto.c titi.c` découpé en « `ls` », « `-l` », « `toto.c` », « `titi.c` ».

Substitutions, expansions : l'interprétation des blancs

- L'interprétation des blancs arrive après les substitutions de variables
  ⇒ `x="fichier avec espace.txt"; ls -l $x` cherche trois fichiers ...
- L'interprétation des blancs arrive avant l'expansion des wildcards
  ⇒ `ls -l *` marche correctement même avec des espaces dans les noms de fichiers.

Jouer avec l'interprétation des blancs : les guillemets

Backslash `\x` considère `x` comme un caractère « normal »
- `ls -l fichier\ avec\ espaces.txt` fait ce qu'il faut.

Guillemets simples (single quotes) `'chaine de caractere'` : seul le guillemet simple est encore un caractère spécial. Les blancs, dollars et autres sont des caractères comme les autres.
- `ls -l 'fichier avec espaces.txt'` marche.
- `ls -l 'fich$avec<cars!speciaux.txt'` aussi.

Guillemets doubles (double quotes) `"chaine de caracteres"` : les blancs ne sont plus des caractères spéciaux, le shell ne coupera pas la chaine en deux. `$`, `!`, `\` sont encore actifs, mais pas les wildcards (`*`, ...)
- `ls -l "$x"` est la manière correcte d'appeler `ls -l` sur un fichier contenu dans la variable `x`.
- `ls -l "\$x"` affiche le fichier « `$x` ».

Guillemets et variable

- Règle d'or :

  Si on n'a pas une bonne raison de faire autrement, on met toujours des guillemets doubles autour des variables.
- `"$toto"` = :-)
- `$toto` = :-(

Expansion de commande : `$(...)`

- `ls -l $(commande)` exécute `commande`, et remplace `$(commande)` par le résultat.
- `ls -l $(find . -name "*.c")` va exécuter `ls -l` avec tous les fichiers `.c` trouvés dans un sous-répertoire du répertoire courant (attention, non robuste aux espaces dans les noms de fichiers) ;

Expansion arithmétique

`$((...))` évalue le contenu « `...` » comme une expression.

Exemples
- `echo $((40 + 2))` (affiche 42)
- `x=$((x + 1))` (incrémente `x`)
- `x=$(($x + 1))` (idem)

Entrées-sorties dans un terminal Unix

- Sous Unix, chaque processus peut
  - Lire des entrées (au clavier),
  - Écrire une sortie (à l'écran),
  - Émettre des messages d'erreur (confondus avec la sortie par défaut).

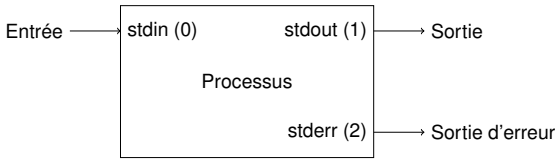

Une des commandes les plus simples : « cat »

- `cat` sans argument :
  - Lit des lignes au clavier
  - Affiche la même chose à l'écran
- Pour envoyer une fin de fichier au clavier : `C-d`.

Demo


Fonctionnement de cat

Une autre commande très simple : « echo »

- `echo arguments` : affiche ses arguments à l'écran.

```
$ echo bonjour
bonjour
$ echo au  revoir
au revoir
```


Redirection des entrées-sorties

Redirection de la sortie standard `echo bonjour > fichier.txt` :
- exécute `echo bonjour`
- met la sortie dans `fichier.txt` au lieu de l'afficher.

Redirection de l'entrée `commande < fichier.txt`

Exemples avec cat
- L'éditeur de texte le plus simple au monde : `cat > fichier.txt`
- Afficher le contenu d'un fichier : `cat < fichier.txt` (ou `cat fichier.txt`).

Redirection des erreurs

- `ls -l foo.c bar.c > sortie.txt 2> erreurs.txt`
  - `sortie.txt` reçoit la sortie (liste des fichiers)
  - `erreurs.txt` reçoit les erreurs (fichiers inexistants, erreurs d'accès disque...)
- Ignorer les erreurs : `commande 2>/dev/null` (`/dev/null` est un fichier spécial « puits sans fond »)

Redirections, pipes

- On peut mettre plusieurs processus bout à bout.
- Exemple : `ls | wc -l`

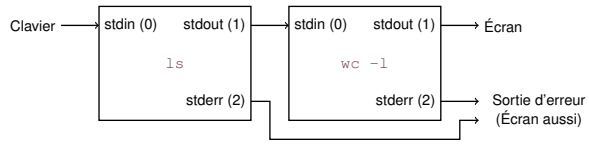

Question

Que fait ce `ls | wc -l` ?

- Combinables à volonté :

```
cmd1 | cmd2 | cmd3
cmd1 < in.txt | cmd2 | cmd3 > out.txt
```


Tout premier script

- Un script-shell = fichier commençant par `#! /bin/sh`
- Exemple :

```
#! /bin/sh

echo 'Bonjour, ceci est mon premier script'
echo "Ca y est, c'est deja fini ..."
```

- Il faut le rendre exécutable : `chmod +x fichier-script`
- Et on l'exécute : `./fichier-script`

`if ... then ... else ... fi`

- Syntaxe :

```
if commande; then
   instruction1
   instruction2
else
   instruction3
fi
```

- Sémantique : exécute `commande`, et la branche `then` ssi la commande a terminé sur un statut 0 (i.e. `$?` est 0).
- Exemple (simpliste) :

```
if ls toto.txt; then
   echo "ls a reussi"
else
   echo "ls a echoue"
fi
```


Syntaxe alternative

```
if [ -f "$fichier" ]; then ...
```

- Commande `[` équivalente à `test`, mais exige que son dernier argument soit `]`

Scripts shell Vs Shell interactif

- « Script » = « programme », en général « vite fait bien fait » et basé sur des chaînes de caractères.
- Tout ce qui peut être tapé dans un shell peut aussi être mis dans un script
- Et inversement !

Conditions, statut de retour, ...

- À la fin de l'exécution, un processus dit « si tout s'est bien passé » avec un nombre.
  - 0 si tout s'est bien passé
  - > 0 si il y a eu une erreur (grave ou pas)
- Accessible avec la variable `$?` :

```
$ ls fichier.txt
fichier.txt
$ echo $?
0
$ ls fichier-inexistant.txt
ls: fichier-inexistant.txt: No such file or directory
$ echo $?
2
```

- En C, c'est la valeur renvoyée par la fonction `main`.

Conditions : `test`

- `test` = commande qui fait des tests en fonctions de ses arguments.
- Exemple : `test -f toto.txt` renvoie 0 si `toto.txt` est un fichier.
- Tests possibles (entre autres)
  - -f arg `arg` est un fichier
  - -d arg `arg` est un répertoire
  - -x arg `arg` est exécutable
  - -e arg `arg` existe (fichier, répertoire, ...)
  - ch1 = ch2 `ch1` est égal à `ch2`
  - ch1 != ch2 `ch1` n'est pas égal à `ch2`
  - Comparaisons de nombres `-eq`, `-ge`, `-gt`, `-le`, `-lt`, `-ne` : equal, greater or equal, greater than, lower than, lower or equal, not equal.
- `man test`

Opérations booléennes

`[ ... ] && [ ... ]` « et » booléen

`[ ... ] || [ ... ]` « ou » booléen

`[ ! ... ]` ou bien `! [ ... ]` « non » booléen

Exemple :

```
if [ -r "$file" ] && ! [ -L "$file" ]
then
    echo "$file is readable and"
    echo "is not a symbolic link"
fi
```

Exemple de if/then/else : les fichiers

```
if test -f "$fichier"; then
  echo "$fichier est un fichier"
elif test -d "$fichier"; then
  echo "$fichier est un repertoire"
else
  echo "c'est autre chose"
fi
```


Exemple de if/then/else : chaines, nombres

```
if [ "$chaine" = "toto" ] || [ "$chaine" = "tutu" ]
then
  echo "chaine est egal a toto ou tutu"
elif [ "$nombre" -lt 4 ]
then
  echo "$nombre est plus petit que 4"
elif [ "$nombre" -ge 4 ]
then
  echo "$nombre est plus grand ou egal a 4"
fi
```

⚠ Les espaces sont importants !

for ... in ... done

```
for i in un deux trois; do
  echo "cette fois, i vaut $i"
done
```

affiche

```
cette fois, i vaut un
cette fois, i vaut deux
cette fois, i vaut trois
```


Exemple utile avec for

```
for i in *.py; do
  ... $i ...
done
```


while ... do ... done

```
while commande; do
  bloc d'instructions
done
```

- Exécute la commande, et si elle renvoie 0, execute le bloc d'instructions et reboucle.
- Très utile avec `test`, comme pour `if`.

case ... in ... esac

```
case "$i" in
    "valeur")
        echo "i vaut valeur"
        ;;
    --*)
        echo "i commence par tiret-tiret"
        ;;
    "un"|"deux")
        echo "i est soit un soit deux"
        ;;
    *)
        echo "i est autre chose"
        ;;
esac
```


Passage de paramètres à un script

- `$1`, `$2`, ..., `${42}` : premier, deuxième, ..., quarante-deux-ième arguments du script.
- `"$@"` : tous les arguments
- `$#` : nombre d'arguments
- `$0` : nom de l'exécutable (ou pas)
- Exemple :

```
#! /bin/sh

echo "l'executable est $0"
echo "le premier argument est $1"
echo "le deuxieme est $2"
echo "et au total, il y a $# arguments"
```


Passage de paramètres

- `set arg1 arg2` ... : remplace les arguments `$1`, `$2`, ...par `arg1`, `arg2`, ...
- `shift` : oublie `$1`, et décale `$2`, `$3`, ...vers la gauche.
- Exemple :

```
#! /bin/sh

echo "$0" "$@"
set un deux trois
echo "$0" "$@"
shift
echo "$0" "$@"
```

et `./mon-script one two` affichera :

```
./mon-script one two
./mon-script un deux trois
./mon-script deux trois
```

Exercice

- Faire un script qui, pour chaque argument :
  - Affiche « option un » si l'argument est « `--un` »
  - Affiche « autre option » si l'argument commence par « `--` »
  - Affiche « autre chose : argument » sinon.
- Utiliser `while`, `test`, `case`, `shift`, `$#` et `$1`.

Exercice : solution

```
#! /bin/sh
while test $# -ne 0; do
    case "$1" in
        "--un")
            echo "option un"
            ;;
        "--"*)
            echo "autre option"
            ;;
        *)
            echo "autre chose"
            ;;
    esac
    shift
done
```

⇒ Très utile pour « parser » la ligne de commande
(nb : on peut aussi utiliser getopt (man 1 getopt) ou getopts (man bash))

Fonctions en shell

- Déclaration :

```
ma_fonction () {
    echo "appel de ma_fonction avec arguments"
    echo "$1, $2, $3 ... ($# au total)"
}
```

- Appel : comme une commande

```
ma_fonction "premier argument" arg2 arg3 arg4
```


`man` : manuel

- Attention, toute cette section donne une vue très succinte des possibilités de chaque commande
- `man` *`commande`* pour les détails
- `man man` ...

`cat`

- `cat` sans argument : lit sur son entrée standard, recopie sur sa sortie standard (pas très utile)
- `cat fichier` : affiche le contenu du fichier sur la sortie standard
- `cat fichier1 fichier2 ...` : affiche la concaténation des fichiers sur la sortie standard.
- Exercice : donner une formulation plus simple de
  `cat /etc/passwd | wc -l`
  (UUOC = Useless Use Of Cat)
  ⇒ `wc -l < /etc/passwd` (ou `wc -l /etc/passwd`)

`grep` : Global Regular Expression Print

- `grep toto fichier.txt` : affiche toutes les lignes de `fichier.txt` contenant `toto`.
- `commande | grep toto` : lance `commande`, mais n'affiche que les lignes de la sortie contenant `toto`.
- `grep 'to.o' fichier.txt` : affiche toutes les lignes de `fichier.txt` contenant la chaine `to` suivie de n'importe quel caractère, suivi d'un `o`.
- ⇒ grep recherche en fait une expression régulière ...

Expressions régulières (regexp)

- Basée sur la théorie des langages. . .avec une syntaxe texte :
  - `a` : le caractère `a`
  - `abc` : la chaîne `abc`
  - `.` : n'importe quel caractère
  - `[abc]` : un des caractères `a`, `b`, ou `c`
  - `[a-z0-9]` : un caractère compris entre `a` et `z` ou entre `0` et `9`
  - `[^abc]` : ni `a`, ni `b`, ni `c`
  - `\(expression\)` : l'expression, avec parenthèses de groupement
  - `expression*` : `expression`, répétée un nombre quelconque de fois
  - `\(expr1\|expr2\)` : `expr1` ou `expr2`
  - `expression?` : l'expression, ou la chaîne vide (ne marche qu'avec `grep -E`)
  - `^` : début de ligne
  - `$` : fin de ligne
  - `\.`, `\?`, ... : le caractère `.`, le caractère `?`, ...

Expressions régulières : exemple

- Liste des connexions d'un utilisateur : `last`

```
telesun:~> last
[...]
moy      pts/12       bauges.imag.fr   Fri Apr 11 15:02   still logged in
autre    pts/42       quelque.part.fr  Fri Apr 11 15:01 - 15:02  (00:01)
moy      pts/7        bauges.imag.fr   Fri Apr 11 15:00   still logged in
moy      pts/7        bauges.imag.fr   Fri Apr 11 15:00 - 15:00  (00:00)
[...]
```

- Liste de mes connexions encore ouvertes :

```
telesun:~>last | grep '^moy.*still logged in *$'
moy      pts/12       bauges.imag.fr   Fri Apr 11 15:01   still logged in
moy      pts/7        bauges.imag.fr   Fri Apr 11 15:00   still logged in
```

- Explications : on affiche chaque ligne qui
  - Commence par `moy` (`^moy`),
  - puis n'importe quoi (`.*`),
  - puis la chaine `still logged in`,
  - puis une suite quelconque d'espaces (`*`) avant la fin de la ligne (`$`).

find

- Rechercher un fichier,
- `find .` : afficher tous les fichiers dans le répertoire courant et ses sous-répertoires,
- `find /home/` : tous les fichiers dans /home/ ou ses sous-répertoires,
- `find . -name '*.py'` : tous les fichiers dont le nom correspond à `*.py`
- `find . -type d` : tous les répertoires
- `find . -name '*~' -exec rm -i {} \;` : exécuter la commande `rm -i` sur tous les fichiers terminant par `~` dans le répertoire courant et ses sous-répertoires.

diff

- Comparer deux fichiers
- Fichiers identiques : statut 0 et pas de sortie.

```
$ diff foo.txt bar.txt
$ echo $?
0
```

- Fichiers différents : statut > 0 et visualisation des différences.

```
$ diff -u hello.c bonjour.c
--- hello.c     2008-04-11 19:49:31.000000000 +0200
+++ bonjour.c   2008-04-11 19:49:49.000000000 +0200
@@ -1,5 +1,5 @@
 int main () {
-        printf("Hello, world\n");
+        printf("Bonjour tout le monde\n");
         return 0;
 }
$ echo $?
1
```


Manipuler des noms de fichiers

- `basename /path/to/toto.txt` : nom du fichier sans le répertoire (`toto.txt`)
- `basename /path/to/toto.txt .txt` : nom du fichier sans le répertoire ni le suffixe donné (`toto`)
- `dirname /path/to/toto.txt` : nom du répertoire (`/path/to`)

cut

- Découper un texte en colonnes
- `cut -f 2` : récupérer la deuxième colonne (délimiteur = tabulation)
- `cut -f 3 -d :` : récupérer la troisième colonne (délimiteur : deux-points)
- Exemple : `cut -f 5 -d : /etc/passwd` : récupérer les noms des utilisateurs.

Trier

- `sort` : trie les lignes de l'entrée par ordre alphabétique
- `uniq` : supprime les doublons dans un ensemble de lignes triées
- Exemple : `last | cut -f 1 -d ' ' | sort | uniq` : liste des utilisateurs qui apparaissent au moins une fois dans `last`.

xargs

- Construit et exécute une commande à partir de son entrée standard
- `cmd1 | xargs cmd2` va exécuter `cmd1`, obtenir une sortie *`sortie`* puis construire puis exécuter la commande `cmd2` *`sortie`*.
- Exemple :
  - `find . -name '*.py' | grep toto` : cherche tous les fichiers `*.py` et n'affiche que ceux dont le nom contient `toto`,
  - `find . -name '*.py' | xargs grep toto` : cherche les `*.py`, et exécute `grep toto fichier1.py fichier2.py ...` (i.e. fait une recherche sur le contenu, pas le nom)

sed : Stream EDitor

- « Éditeur de texte », mais non-interactif. Très puissant pour faire des transformations syntaxiques sur du texte.
- Principale utilité : substitution d'expressions.
  `sed 's/expr/chaine/g'`
  ou `sed 's#expr#chaine#g'`. L'option `g` à la fin permet de remplacer `expr` plusieurs fois sur une même ligne.
- Exemples :
  - `sed 's/toto/titi/g' < fich1.txt > fich2.txt` : remplacer tous les `toto` par des `titi` dans `fich1.txt` et mettre le résultat dans `fich2.txt`
  - `pwd | sed 's#^.*/##'` : obtenir le nom du répertoire courant (équivalent à `basename $(pwd)`)
  - `last | sed 's/^\([^ ]*\) .*$/\1/'` : extraire seulement la première colonne
    - ★ le `\1` est remplacé par ce à quoi la première paire de parenthèses a correspondu
    - ★ Le contenu des `\([^ ]*\)` s'arrête au premier espace.

wc

- Compter les mots, les lignes, les caractères
- `wc *.py`
- `ls | wc`
- ...

read

- Commande interne
- Poser des questions à l'utilisateur du script, attendre et exploiter la réponse
- lire une ligne (jusqu'à `<enter>`) et stocker la valeur dans une variable
- ou bien lire un nombre fixe de caractère
- Exemples :
  - `read -p "Entrez une ligne" ligne` affiche une phrase et attend l'entrée d'une ligne en réponse. La ligne est stockée dans la variable `$ligne`
  - `read -s -n1` attend que l'utilisateur tape une touche sans l'afficher et stocke la touche dans la variable `$REPLY`