

Probabilité: CM6 - Variance et covariance

Toutes les variables aléatoires considérées sont de carré intégrable: $\mathbb{E}[X^2] < \infty$

Définition:

On note variance de la variable aléatoire X :

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}[X])^2]$$

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2$$

et covariance des variables X et Y :

$$\text{cov}(X, Y) = \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$$

$$\text{cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$$

Propriétés:

1. $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{cov}(X, Y)$
2. Si X et Y sont indépendantes, $\text{cov}(X, Y) = 0$
3. $\text{cov}(X, Y)$ est symétrique et bilinéaire

Inégalité de Tchebyshev:

$$\forall t > 0, P(|X - \mathbb{E}[X]| > t) \leq \frac{\text{Var}(X)}{t^2}$$

Loi (faible) des grands nombres:

Soient X_1, X_2, \dots une suite de variable aléatoire de même loi, indépendantes et de carré intégrable ($\mathbb{E}[X_i^2] < \infty$),

$$\overline{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{Var}(\overline{X}_n) = \frac{\text{Var}(X_1)}{n} \rightarrow 0$$

(\overline{X}_n converge vers $\mathbb{E}[X_1]$)

Exercice 1

Soient X, Y deux variables aléatoires telles que

$$Y = a + bX + \epsilon$$

1. $\mathbb{E}[\epsilon] = 0$, ϵ et X sont indépendants
2. On suppose de plus que $Var(X) = 1$ (on divise X par $\sqrt{Var(X)}$ de sorte que X soit sans unité)

Calculer la covariance entre X et Y :

Solution

$$\begin{aligned} cov(X, Y) &= cov(X, a + bX + \epsilon) \\ cov(X, Y) &= cov(X, a) + b.cov(X, X) + cov(X, \epsilon) \\ cov(X, Y) &= b.cov(X, X) \\ cov(X, Y) &= b \end{aligned}$$

Interprétation:

La covariance est (la taille de) l'effet de X sur Y

Exercice 2

Soit Z une variable aléatoire de loi $\mathcal{N}(0, 1)$

$$\forall z \in \mathbb{R}, f_Z(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$$

On pose $X = m + \sigma Z$:

1. Espérance et variance de Z
2. Espérance et variance de X
3. Densité de la loi de X

Solution

1. $\mathbb{E}[Z] = 0$ et

$$Var(Z) = \mathbb{E}[Z^2] - \mathbb{E}[Z]^2 = 1$$

2. $\mathbb{E}[X] = \mathbb{E}[m + \sigma Z] = m + \sigma \mathbb{E}[Z] = m$ et

$$Var(X) = Var(m + \sigma Z) = Var(\sigma Z) = \sigma^2 Var(Z) = \sigma^2$$

3. $Z = \frac{X-m}{\sigma} = \frac{X-\mathbb{E}[X]}{\sqrt{Var(X)}} \text{ (normalisation)}$

$$\begin{aligned}
 P(X \leq t) &= \int_{-\infty}^t f_X(x) dx \\
 &= P\left(Z < \frac{t-m}{\sigma}\right) = \int_{-\infty}^{\frac{t-m}{\sigma}} f_Z\left(\frac{x-m}{\sigma}\right) \frac{dx}{\sigma}
 \end{aligned}$$

La densité est

$$\forall x \in \mathbb{R}, f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-m)^2}{2\sigma^2}}$$

Exercice 3

Soit p une fonction de densité sur \mathbb{R} .

On appelle entropie de p la fonction suivante:

$$H(p) = -\mathbb{E}[\ln(p(X))]$$

où X suit la loi de densité p

1. Calculer $h(m, \sigma^2) = H(\mathcal{N}(m, \sigma^2))$
2. On admet l'inégalité de Gibbs,

Soit p, q deux densités sur \mathbb{R} , et X une va de loi de densité q

$$d_{KL}(q||p) = \mathbb{E}_q\left[\ln\left(\frac{q(X)}{p(X)}\right)\right] \geq 0$$

Soit $q(x)$ une densité définie sur \mathbb{R} , de moyenne m et de variance σ^2 , alors:

$$H(q) \leq h(m, \sigma^2)$$

Parmi toutes les lois sur \mathbb{R} qui ont une variance σ^2 , l'incertitude est maximisée pour la loi $\mathcal{N}(m, \sigma^2)$

1. Soit $p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-m)^2}{2\sigma^2}}$ alors,

$$\begin{aligned}
 H(p) &= -\int \ln(p(x))p(x)dx \\
 H(p) &= -\mathbb{E}_p[\ln(p(X))] \\
 H(p) &= -\mathbb{E}_p\left[\ln\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right) - \frac{(X-m)^2}{2\sigma^2}\right] \\
 H(p) &= \frac{1}{2}[\ln(2\pi\sigma^2) + \mathbb{E}[Z^2]] \\
 H(p) &= \frac{1}{2}[\ln(2\pi\sigma^2) + 1] \\
 \mathbb{E}_q\left[\ln\left(\frac{q(X)}{p(X)}\right)\right] &= -H(q) - \mathbb{E}_q[\ln(p(X))] \\
 \mathbb{E}_q\left[\ln\left(\frac{q(X)}{p(X)}\right)\right] &= -H(q) + h(m, \sigma^2)
 \end{aligned}$$

D'après l'inégalité de Gibbs

$$H(q) \leq h(m, \sigma^2)$$