

d) Types d'histogramme:

→ Histogramme à classe de même largeur:

- On a $\forall j \in \llbracket 2, m \rrbracket$ $h_j = \text{cte} \Rightarrow h_j = \frac{aK}{K}$ (K : nombre de classes)

⇒ On trace les a classes

classe $]a_{j-1}, a_j]$	---	
Effectif n_j		
freq: n_j/n		
hauteurs: $\frac{n_j}{n h_j}$		

• À partir de ce tableau on peut dessiner facilement l'histogramme.

→ Histogramme à classes de même effectif:

- Histogramme tel $\forall j \in \llbracket 2, n \rrbracket$ $n_j = \text{cte} \Rightarrow n_j = \frac{n}{K}$ (K : nombre de classes)

• Les classes de $h_j \neq \text{cte}$

classe $]a_{j-1}, a_j]$			
Effectif n_j	n/K
freq: n_j/n			
hauteurs: $\frac{n_j}{n h_j}$			

• À partir de ce tableau on peut dessiner facilement l'histogramme.

Re: à partir des listes $(x_i)_i$ des observations on peut tracer les $(h_j)_j$

Re:

* Les histogrammes à classe de même effectif décrivent plus finement la distribution que les histogrammes à classe de même largeur.

5) Fonction de répartition empirique:

a) Def:

* La fonction de répartition empirique (EDRE) F_n associée à un échantillon x_1, \dots, x_n est la fonction définie par:

• $\forall x \in \mathbb{R}, F_n(x) = \text{pourcentage d'observations inférieures à } x$

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n 1_{\{x_i \leq x\}} = \begin{cases} 0 & \text{si } x < x_1^* \\ \frac{i}{n} & \text{si } x_i^* \leq x < x_{i+1}^* \\ 1 & \text{si } x \geq x_n^* \end{cases}$$

Re:

- $F_n(x)$ est une estimation de $F(x)$
- On peut montrer que cette estimation est d'excellente qualité
- Déterminer le modèle probabiliste à partir de la EDRE n'est pas facile à faire correctement mais on utilise plutôt graphes de probabilités

b) Graphes de probabilités:

* Def: est un nuage de pts tracé à partir de la fonction de répartition empirique F_n . Ses pts doivent être approximativement alignés si les observations proviennent d'une loi de probabilité bien précise

* Méthode:

* Obj: On souhaite savoir si les observations sont issues de loi probabiliste dépendant d'un paramètre θ inconnu, dont la fonction de répartition est F .

* Principe: chercher une relation affine du type $h[F(x)] = \alpha(\theta)g(x) + \beta(\theta)$

* Résultat: si la vraie fonction de répartition est F , les pts:

$$(g(x_i^*), h(F_n(x_i)) = h(\frac{i}{n})) \text{ seront approximativement alignés}$$

\Rightarrow le pente et s'ordonnée s'expriment en fonction de θ

Re: * Le nuage $(g(x_i^*), h(\frac{i}{n}))$, $i \in \{1, \dots, n\}$ est appelé graphes de probabilités par sa loi de fonction de RF

Exemple 1: graphe de probabilité d'un $X \sim \mathcal{E}(\lambda)$

$$X \sim \mathcal{E}(\lambda), \quad F(x) = \mathbb{P}(X \leq x) = 1 - e^{-\lambda x}$$

$$\forall x > 0 \quad \ln(1 - F(x)) = -\lambda x$$

Alors: le graphe de probabilité d'un $\mathcal{E}(\lambda)$ est à l'origine des pts:

$$\left(x_i^*, \ln\left(1 - \frac{i}{n}\right) \right) \quad i \in \{1, \dots, n-1\}$$

Pour

✓ Estimer de λ

Exemple 2: graphe de probabilité d'un $X \sim \mathcal{CR}(m, \delta)$

$$X \sim \mathcal{CR}(m, \delta) \quad \text{Alors } U = \frac{X-m}{\delta} \sim \mathcal{N}(0,1)$$

$$\forall x \in \mathbb{R} \quad F(x) = \mathbb{P}(X \leq x) = \Phi\left(\frac{x-m}{\delta}\right) \quad \text{ou } \Phi = F_U$$

Alors

$$\Phi^{-1}(F(x)) = \frac{1}{\delta}x - \frac{m}{\delta}$$

Alors: le graphe de probabilité d'un $\mathcal{CR}(m, \delta)$ est à l'origine des pts:

$$\left(x_i^*, \Phi^{-1}\left(\frac{i}{n}\right) \right) \quad i \in \{1, \dots, n-1\}$$

6] Indicateurs statistiques

a) Déf

- Indicateurs statistiques: indicateurs numériques permettant de caractériser au mieux des données quantitatives
- Deux familles d'indicateurs:
 - * Indicateurs de localisation
 - * Indicateurs de dispersion

b) Indicateur de localisation

- * obj: donner un ordre de grandeur général des observations; un nombre unique qui résume au mieux les données.
- * la moyenne empirique: $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$

pe d'ap LFGN $\bar{x}_n \rightarrow E(X)$

* les valeurs extrêmes :

• $x_1^* = \min(x_i)$ et $x_n^* = \max(x_i)$

Alors $(x_1^* + x_n^*) / 2$ est un indicateur de focalisation

Re

Inconvénient de la moyenne et des valeurs extrêmes : Sensibilité aux valeurs aberrantes.

* La médiane empirique : \tilde{x}_n ou $\tilde{q}_{n, 1/2}$

• Un réel qui partage l'échantillon ordonné en deux parties de même effectif

⇒ La moitié des observations sont inférieures à \tilde{x}_n et l'autre moitié lui sont supérieures

• $\tilde{x}_n = \tilde{q}_{n, 1/2} = \begin{cases} \frac{1}{2} (x_{\frac{n}{2}}^* + x_{\frac{n}{2}+1}^*) & \text{si } n \text{ est pair} \\ x_{\frac{n+1}{2}}^* & \text{si } n \text{ est impair} \end{cases}$

Re

La médiane empirique est insensible aux valeurs aberrantes

c) Indicateurs de dispersion :

* chi

• But : mesure de la 'variabilité' des observations

* Variance Empirique :

• $S_n^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}_n^2$

• S_n^2 : mesure d'écart quadratique moyenne de l'échantillon à sa moyenne

Re

En fait pour (X) donne $S_n'^2 = \frac{n}{n-1} S_n^2$ au lieu de S_n^2

* Écart-type empirique : $S_n = \sqrt{S_n^2}$, Interprétation : il s'exprime dans

la même unité que les données

* Coefficient de variabilité empirique :

$CV_n = \frac{S_n}{\bar{x}_n}$

Re - si $CV_n > 0,15 \Rightarrow$ l'échantillon possède une variabilité significative

• si $CV_n \leq 0,15 \Rightarrow$ la moyenne empirique est un bon résumé de tout l'échantillon

d) quantiles empiriques :

* Les quantiles empiriques sont des valeurs qui partagent l'échantillon ordonné en un certain nombre de parties de même effectif.

2 parts \Rightarrow médiane \tilde{x}_n

4 parts \Rightarrow quartiles : $\tilde{q}_{n,1/4}$, $\tilde{q}_{n,3/4}$

10 parts \Rightarrow déciles : $\tilde{q}_{n,1/10}$, ..., $\tilde{q}_{n,9/10}$

* quantiles empiriques de l'échantillon x_1, \dots, x_n :

$$\forall p \in]0,1[\quad \tilde{q}_{n,p} = \begin{cases} \frac{1}{2} (x_{np}^* + x_{np+1}^*) & \text{si } np \text{ est entier} \\ x_{[np]+1}^* & \text{si non} \end{cases}$$

Re : toutes les quantiles définies dans ce chapitre sont ~~elles~~ $\hat{\theta}$ des descripteurs pour des VA.

i) FdRE : $F_n(x) = \frac{1}{n} \sum_{i=1}^n 1_{\{x_i \leq x\}}$

ii) $\bar{x}_n = \frac{1}{n} \sum_{i=1}^n x_i$

iii) $s_n^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)^2$

iv) $\hat{q}_{n,p} = \begin{cases} \frac{1}{2} (x_{np}^* + x_{np+1}^*) & \text{si } np \text{ est entier} \\ x_{[np]+1}^* & \text{si non} \end{cases}$