Systèmes de gestion des fichiers

Plan du chapitre

- Introduction
- Organisation logique
  - Fichiers
  - Désignation et catalogues
- Mise en œuvre des SGF
  - Gestion de l'espace libre
  - Descripteurs de fichiers
  - Amélioration des performances
- Fiabilité du SGF
- Le SGF de PedagOS

Définitions

- Fichier = unité d'information
- Noms de fichiers et catalogues
- Système de gestion des fichiers : SGF

Pourquoi des fichiers

- Permanence des informations
- Partage entre utilisateurs
- Stockage d'informations de grande taille

Organisation logique : les fichiers

- Structure des fichiers
- Types, suffixes, attributs
- Accès aux fichiers
- Opérations sur les fichiers

File Structure

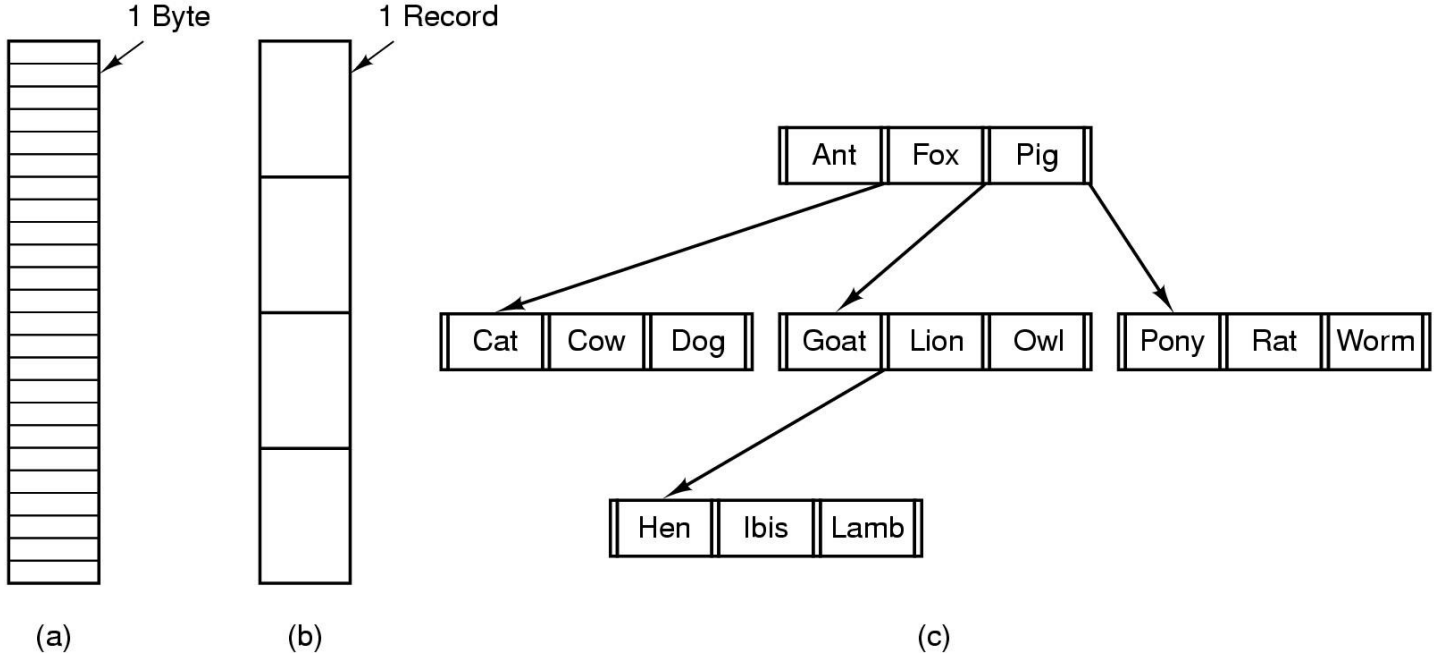

- Three kinds of files
  - byte sequence
  - record sequence
  - tree

File Types

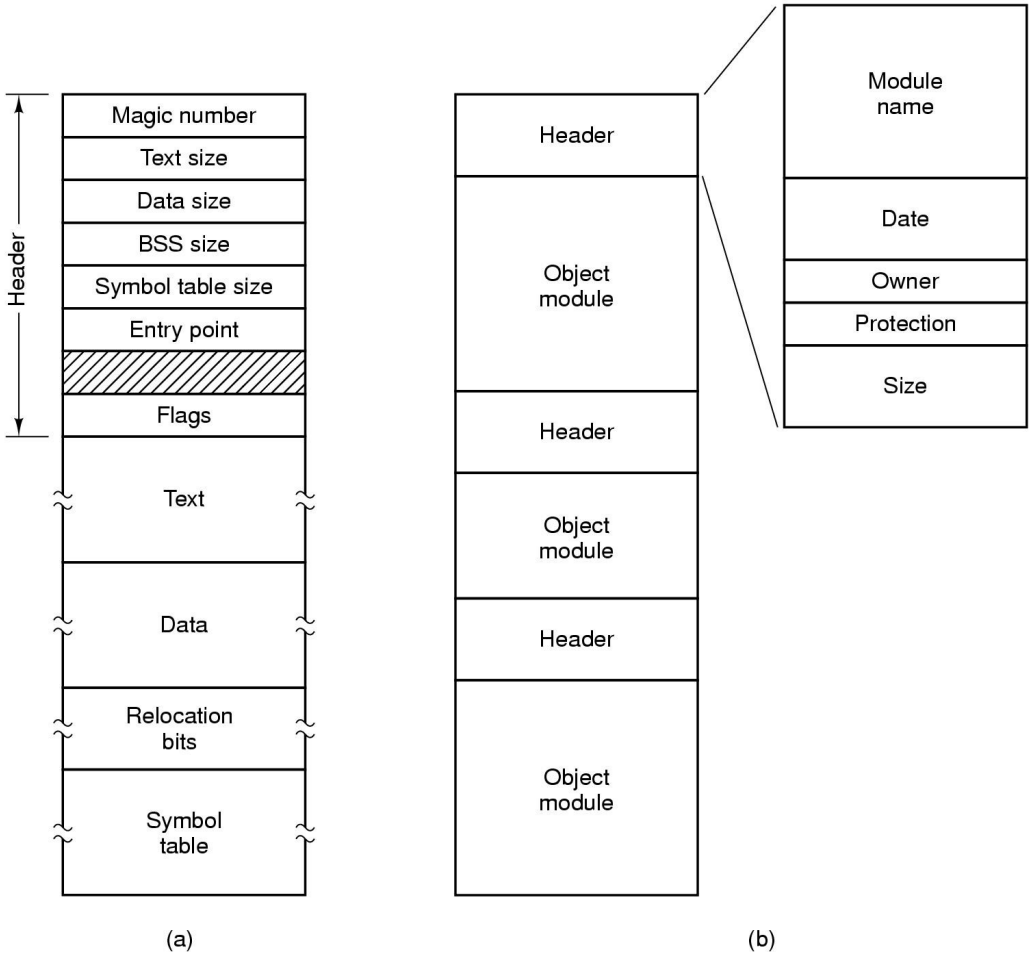

(a) An executable file (b) An archive

Désignation des fichiers : catalogues

- Principe : conserver la correspondance entre un nom de fichier et sa localisation
- Dans une table appelée **catalogue** (directory)
- Catalogue unique, catalogue par utilisateur

Directories
Single-Level Directory Systems

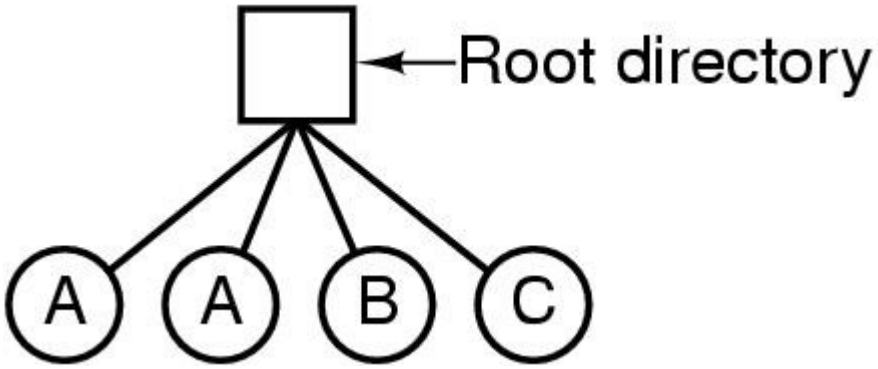

- A single level directory system
  - contains 4 files
  - owned by 3 different people, A, B, and C

Two-level Directory Systems

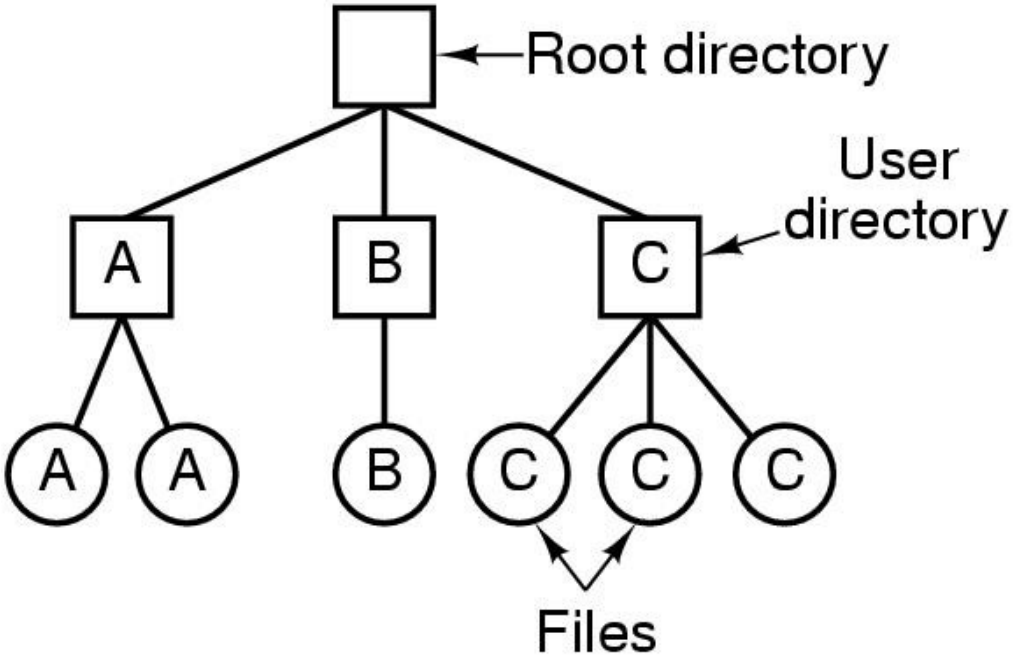

Letters indicate *owners* of the directories and files

Désignation des fichiers : catalogues

- Catalogues hiérarchiques
  - Désignation absolue, relative
  - Catalogue courant
  - . Et ..

Hierarchical Directory Systems

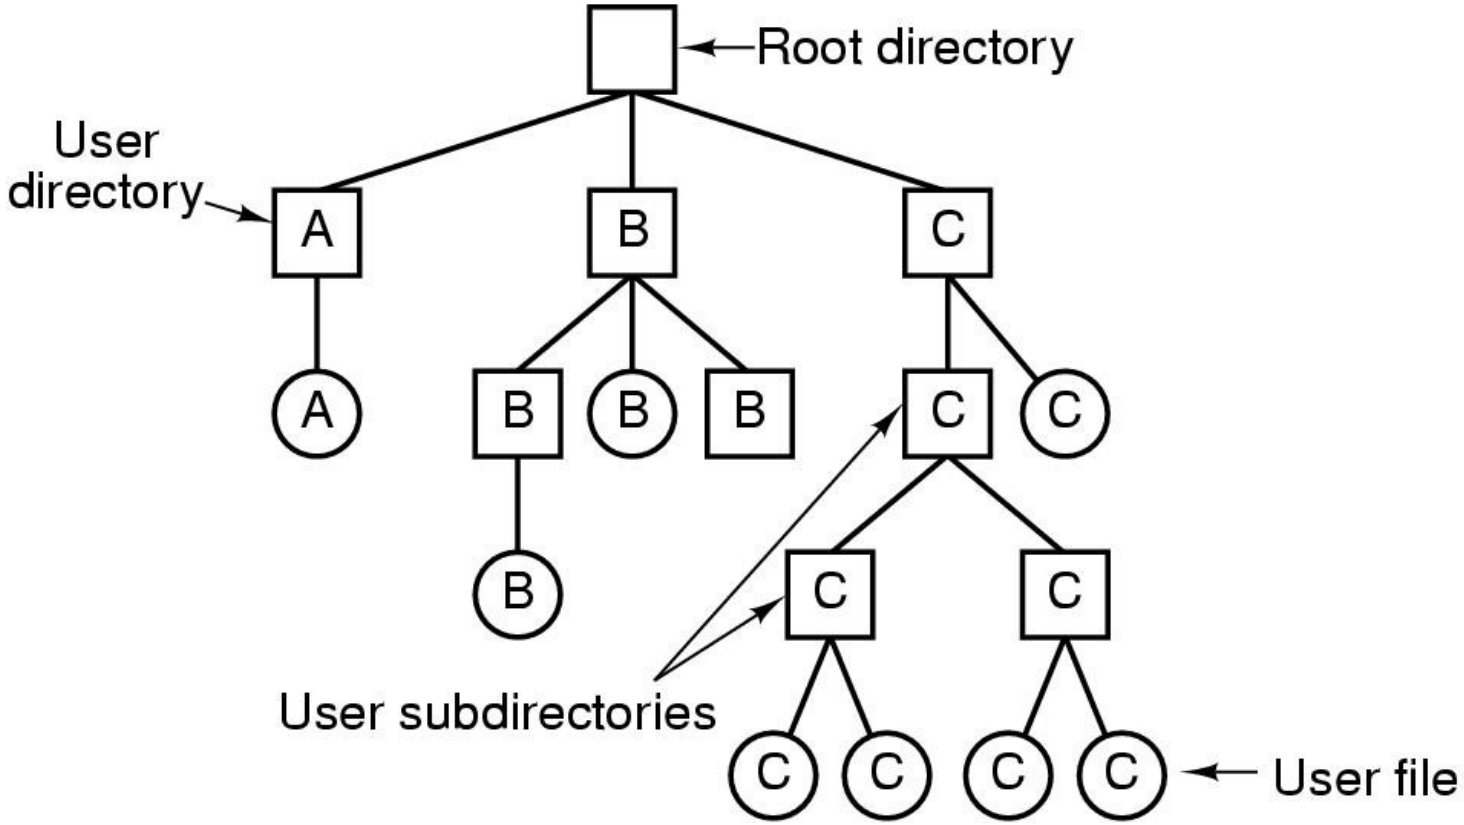

A hierarchical directory system

Path Names

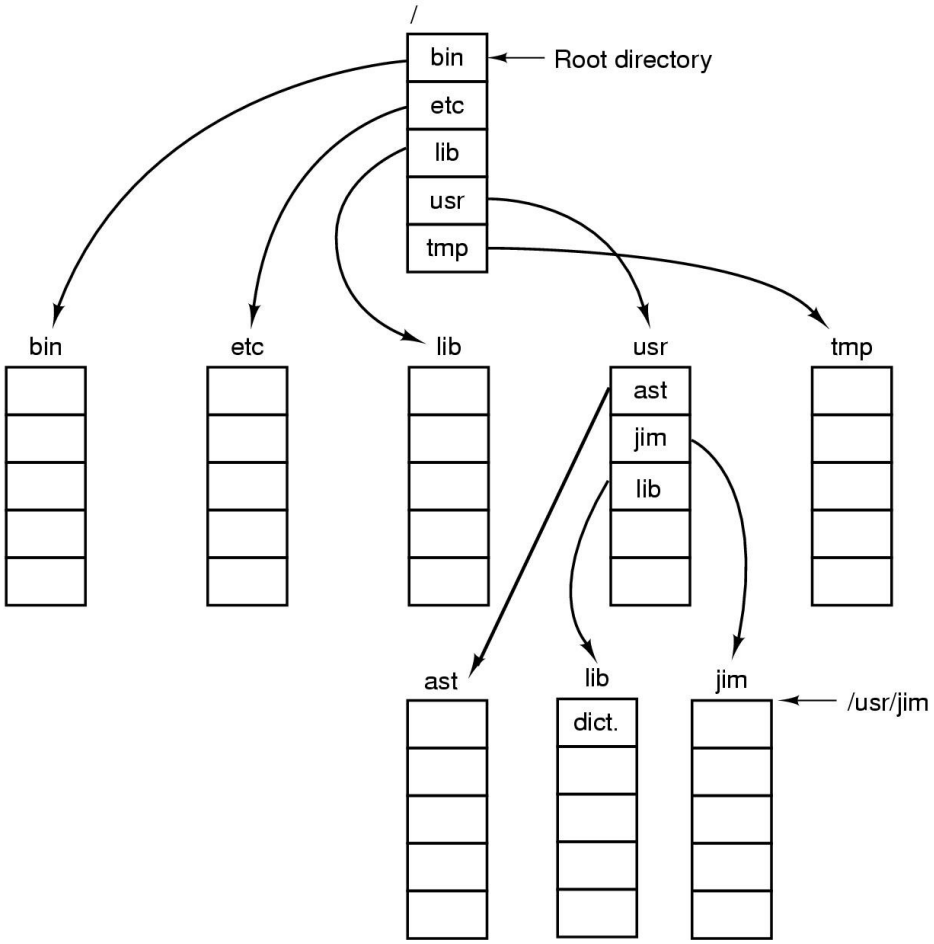

A UNIX directory tree

Désignation des fichiers : catalogues

- Liens et partage de fichiers

Shared Files (1)

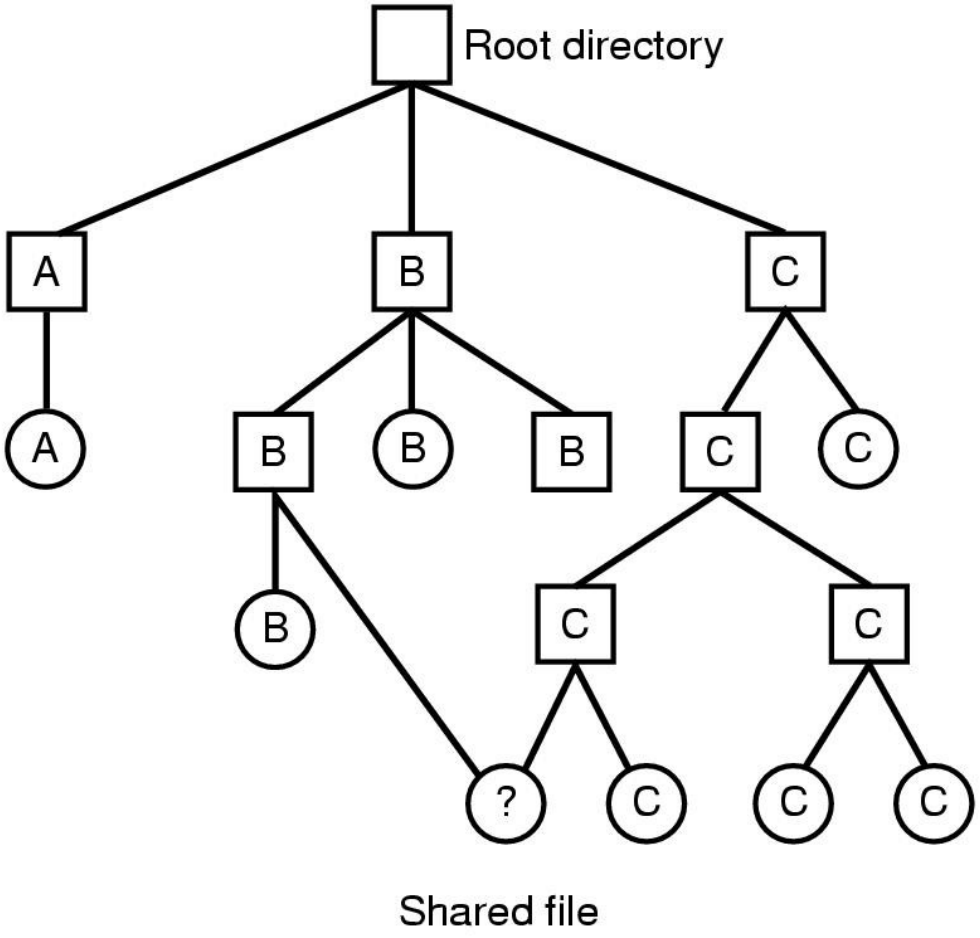

File system containing a shared file

Shared Files (2)

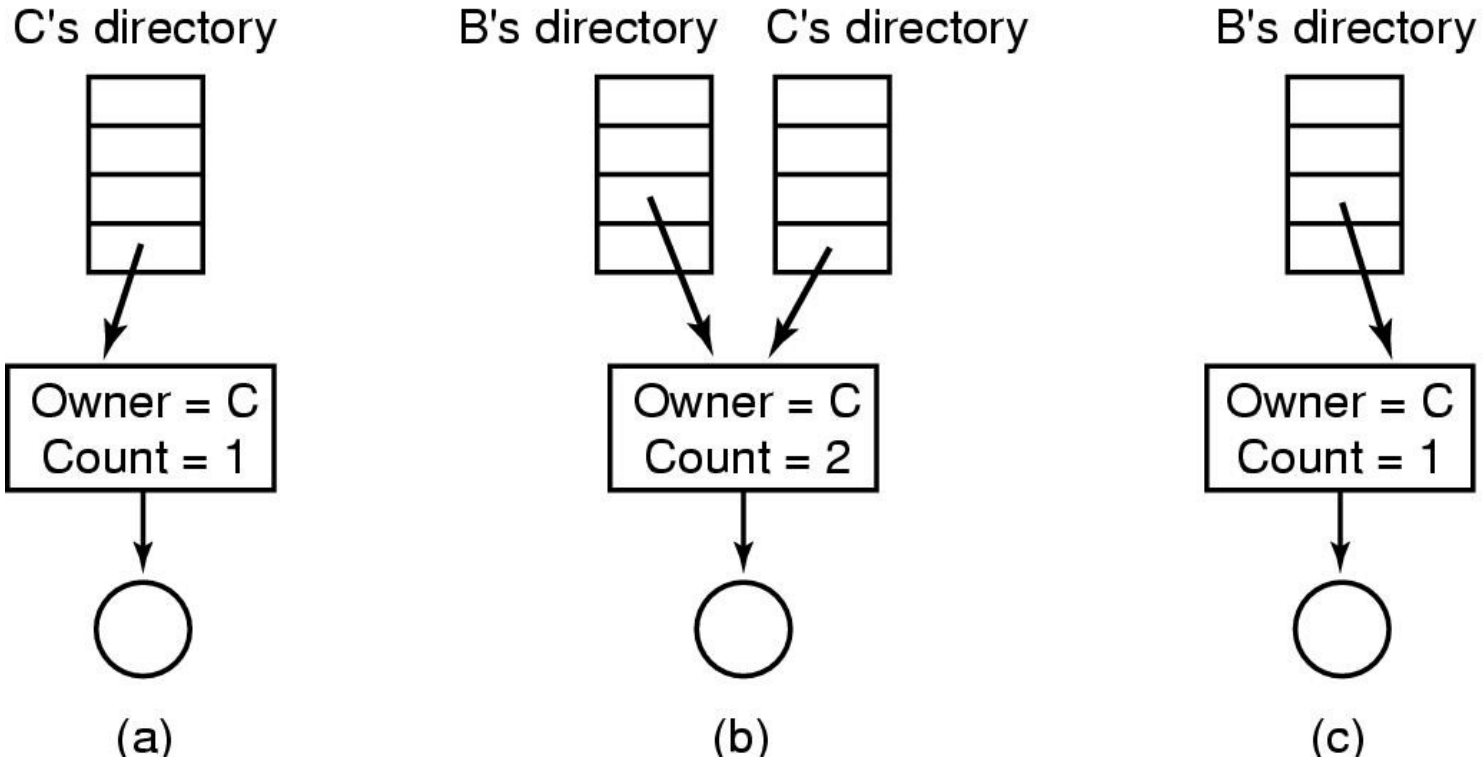

(a) Situation prior to linking

(b) After the link is created

(c)After the original owner removes the file

Mise en Œuvre du SGF

- Réalisation de base
- Extensions pour améliorer les performances

Allocation d'espace disque

- Contraintes : espace de grande taille, accès à forte latence
- Allocation contiguë
- Allocation par blocs de taille fixe
- Gestion des blocs libres ou occupés, descripteurs

Implementing Files (1)

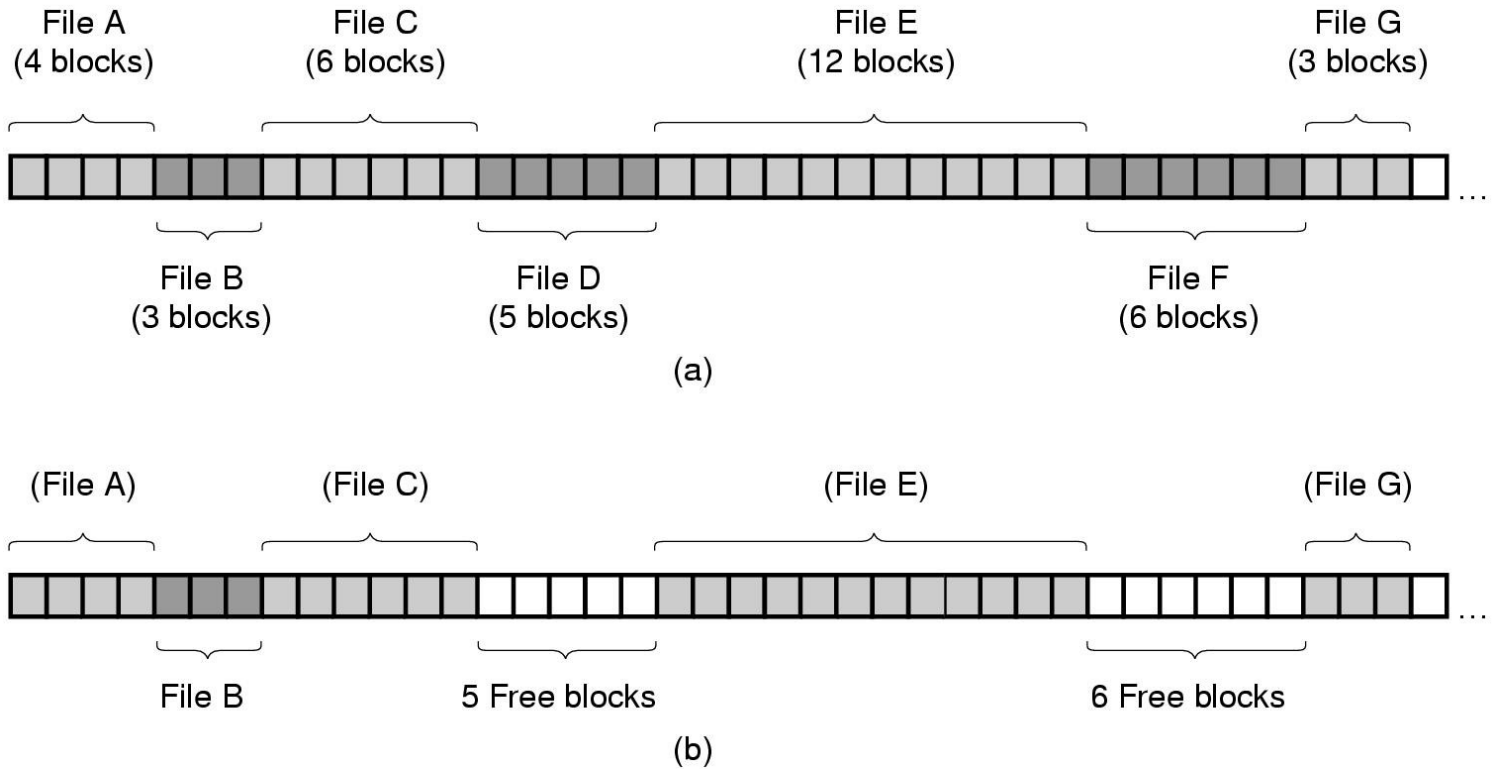

(a) Contiguous allocation of disk space for 7 files

(b) State of the disk after files *D* and *E* have been removed

Implementing Files (2)

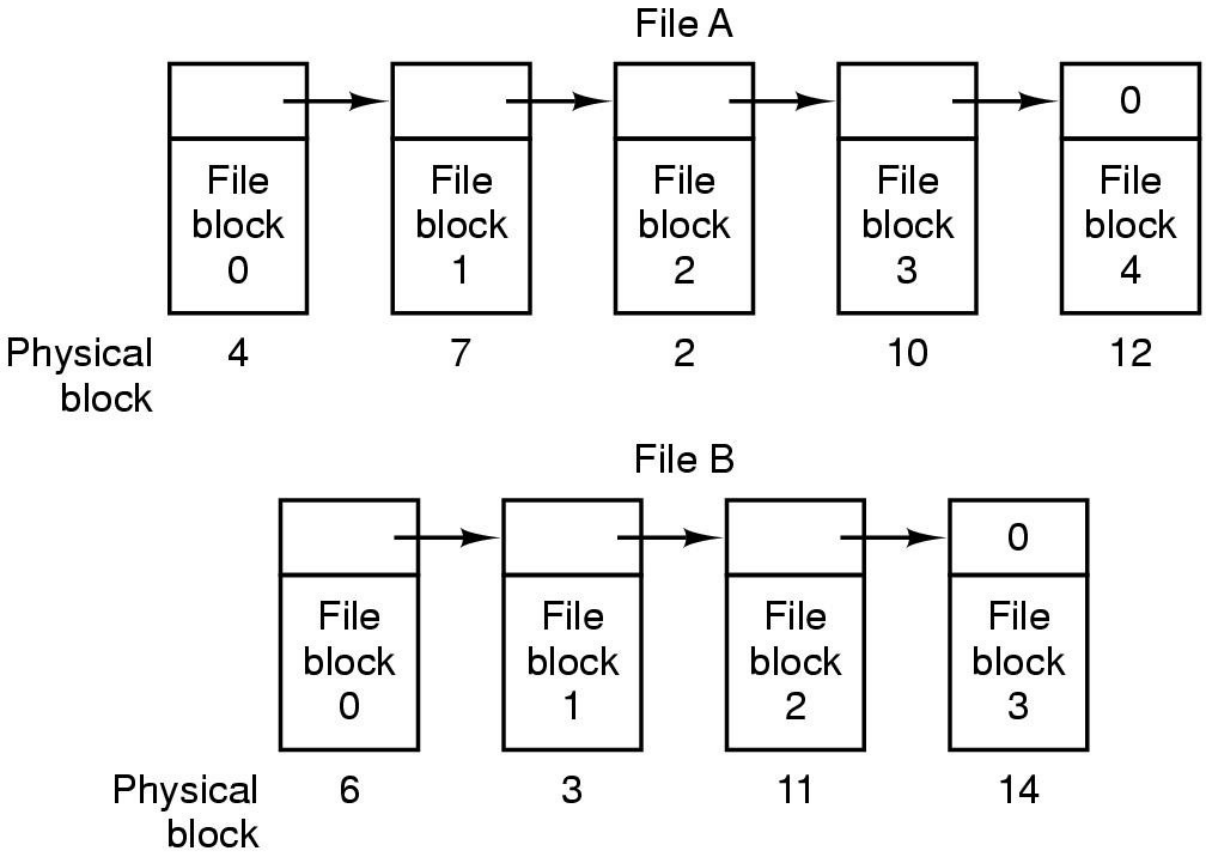

Storing a file as a linked list of disk blocks

Implementing Files (3)

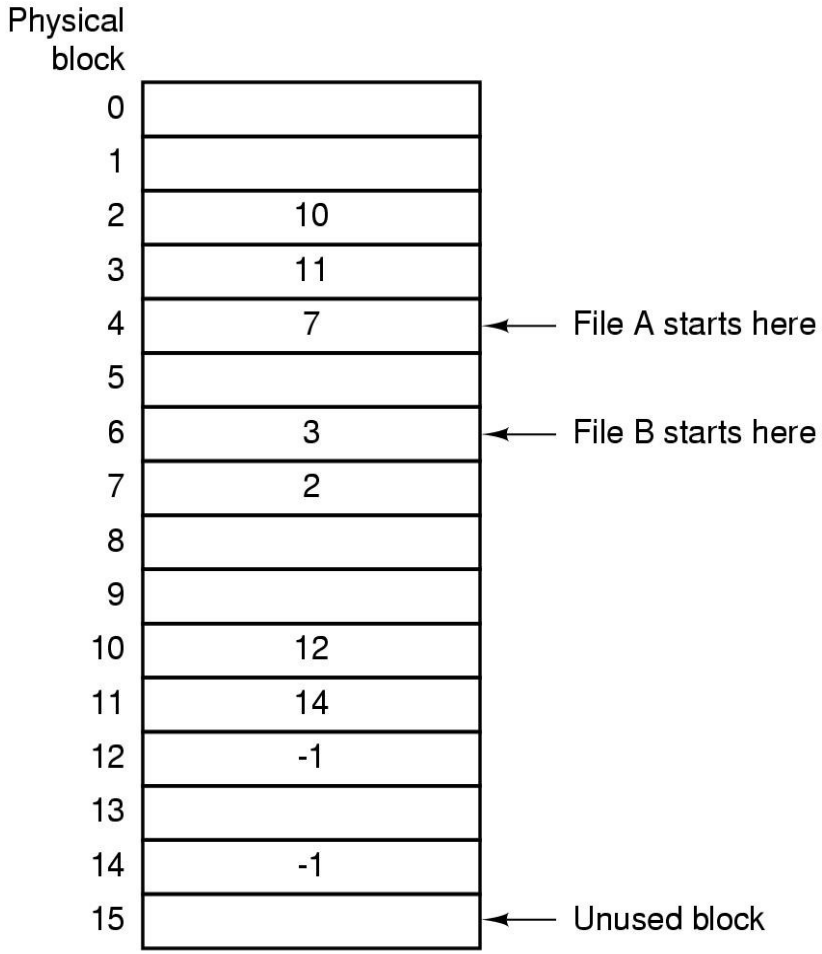

Linked list allocation using a file allocation table in RAM

Représentation des fichiers et des catalogues

- Un exemple de descripteur : le I-node d ’Unix
- Structure des catalogues

The UNIX V7 File System

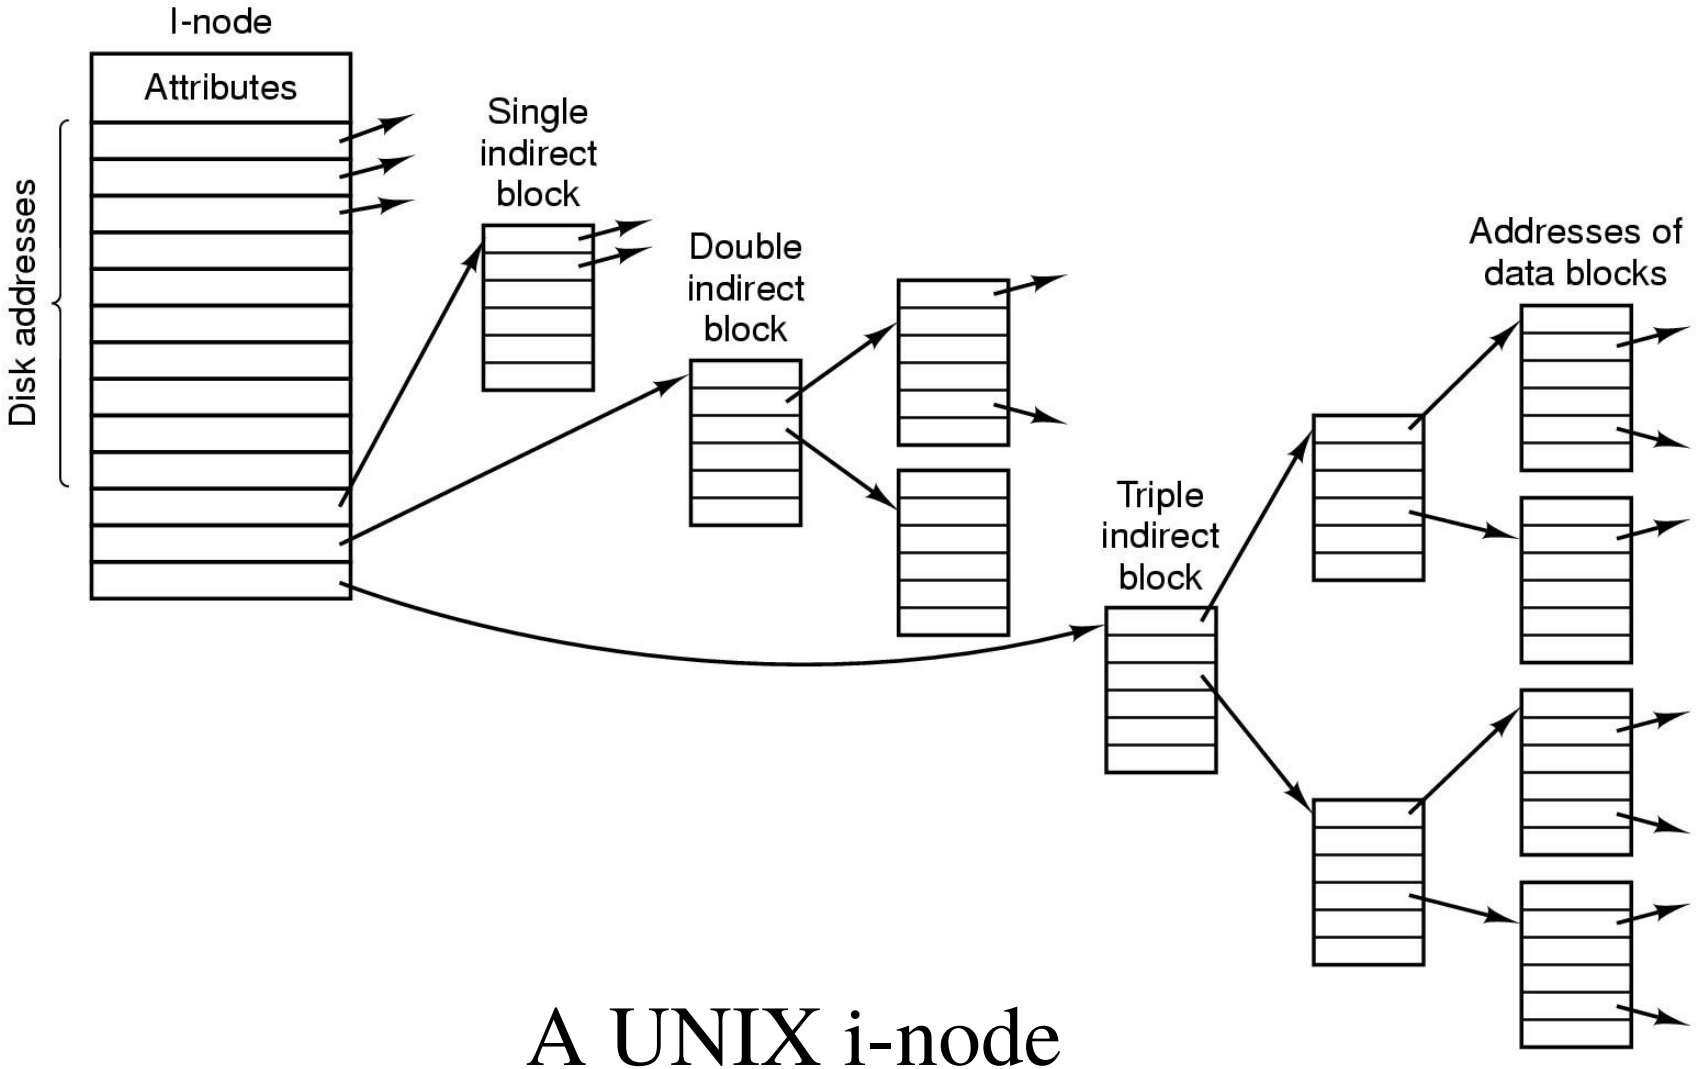

A UNIX i-node

Implementing Directories (1)

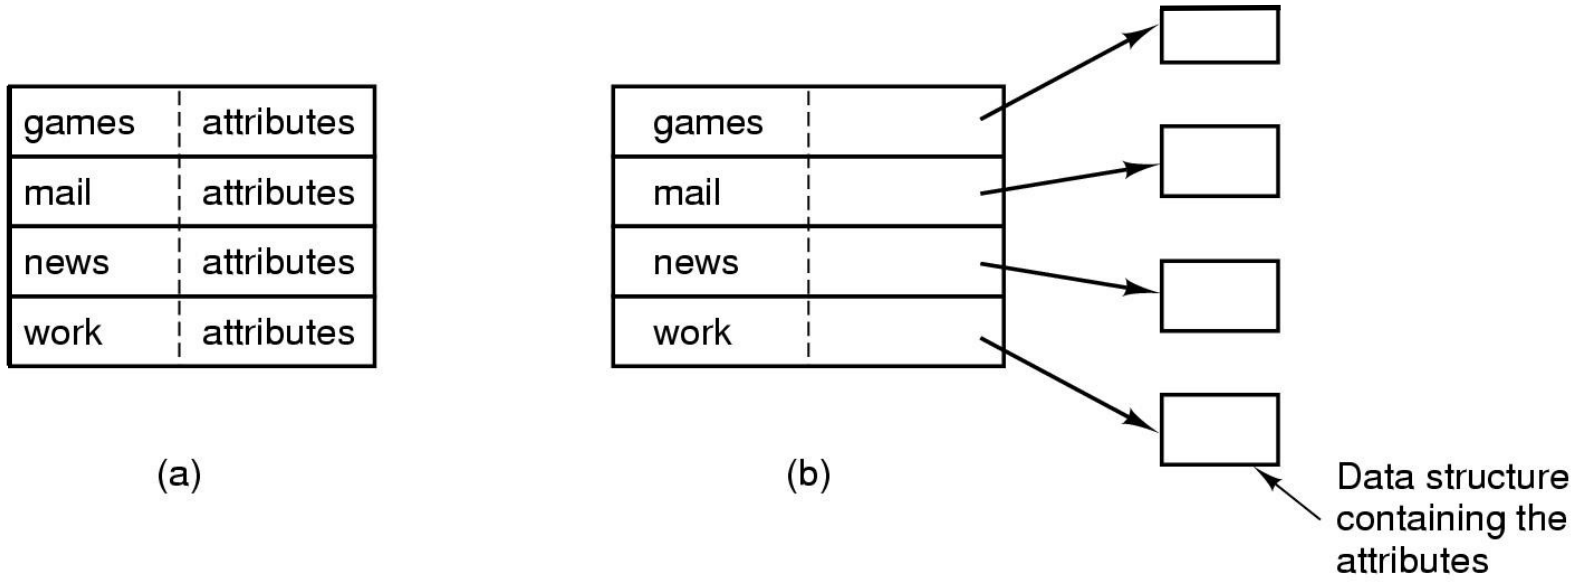

(a) A simple directory

fixed size entries

disk addresses and attributes in directory entry

(b) Directory in which each entry just refers to an i-node

Rappels

- Implantation d'un fichier décrite dans un descripteur, l'i-node du fichier
- Les catalogues sont des fichiers spéciaux
- On trouve à des emplacements connus :
  - La carte des blocs libres
  - L'i-node du catalogue racine

The UNIX V7 File System (1)

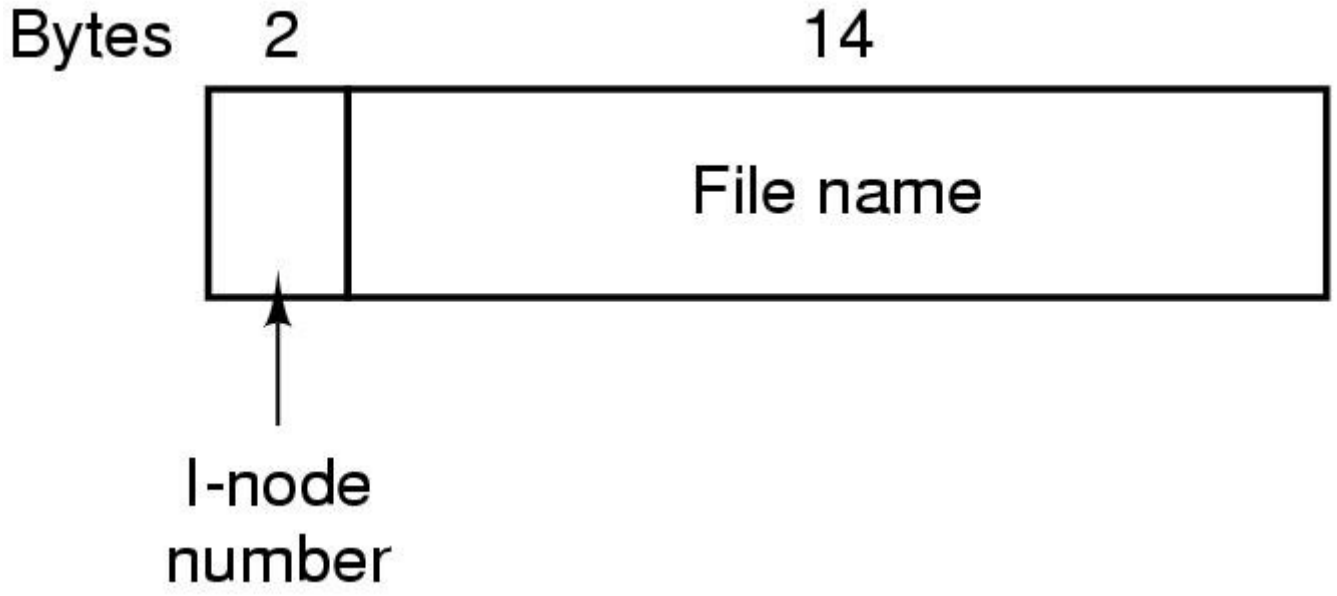

A UNIX V7 directory entry

The UNIX V7 File System (2)

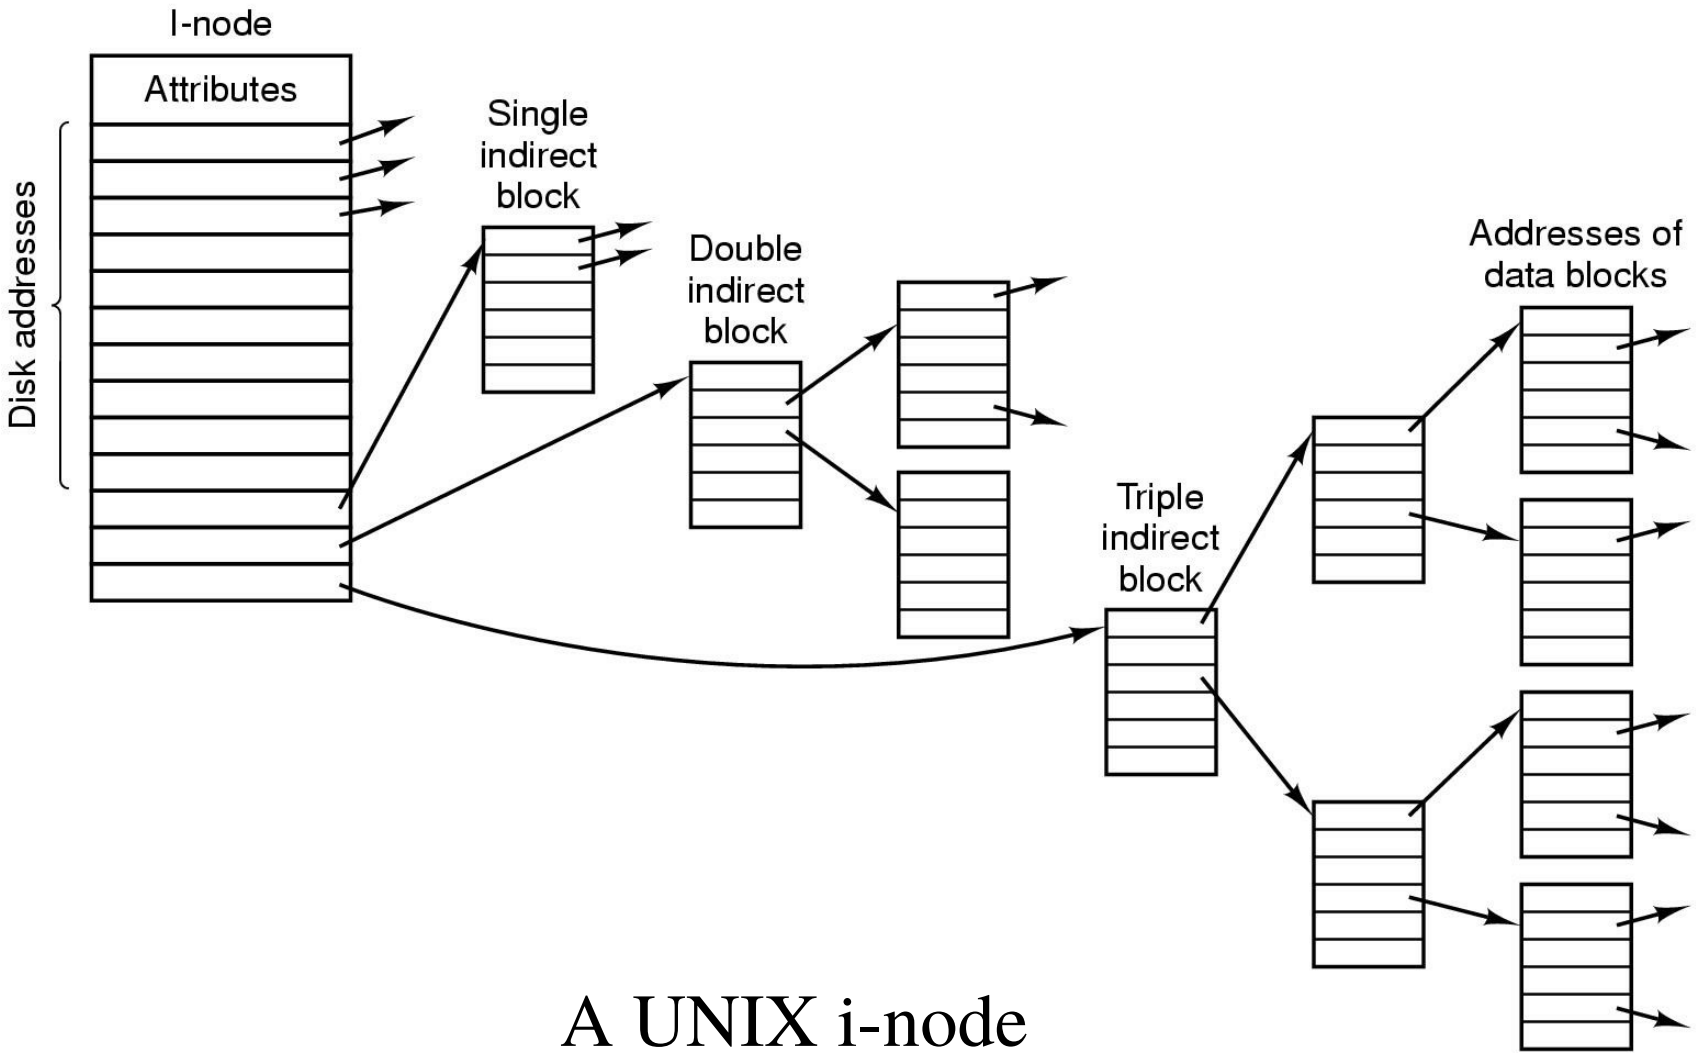

A UNIX i-node

The UNIX V7 File System (3)

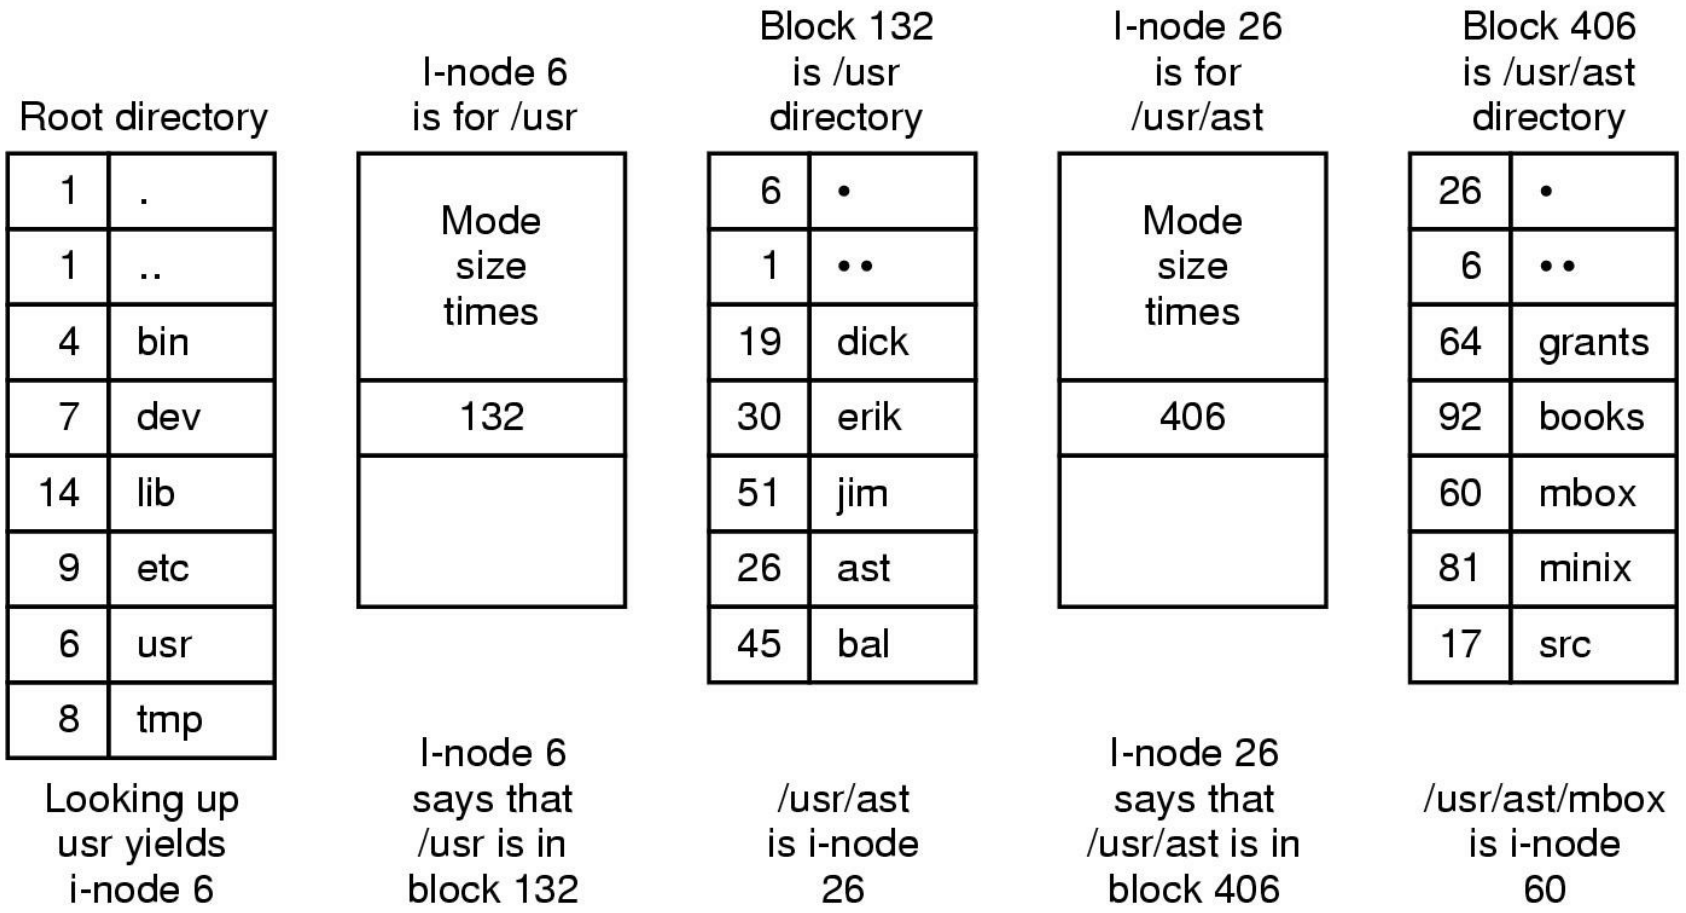

The steps in looking up */usr/ast/mbox*

Résumé

- Allocation d'espace disque par blocs de taille fixe
  - Comment choisir la taille ?
- Fichier = descripteur + ensemble de blocs
- Catalogue assure une correspondance entre une chaîne de caractères et un descripteur

Le programme de la séance

- Comment améliorer l'efficacité
- Comment assurer la sécurité
  - Pannes
  - Malveillances
- Étude de cas : un SGF pour PedagOS

Amélioration de l'efficacité

- Lenteur relative des disques, forte latence
- Accès séquentiel domine
- Plus de lectures que d'écriture
- Beaucoup de petits fichiers à faible durée de vie

Utilisation de tampons en mémoire : le cache du disque

- Transfert systématique d'un bloc entier en mémoire
- Recopie sur disque
  - soit à la fermeture,
  - soit pour libérer un bloc (SOS fiabilité)
  - soit écriture immédiate
- Algorithme de remplacement de bloc

Autres améliorations

- Idée : limiter les déplacements du bras
- Partition en cylindres
  - Nombre fixe d ’I-nodes
  - Bit maps pour emplacements libres
- Allocation des blocs pour favoriser l ’accès séquentiel

File System Performance

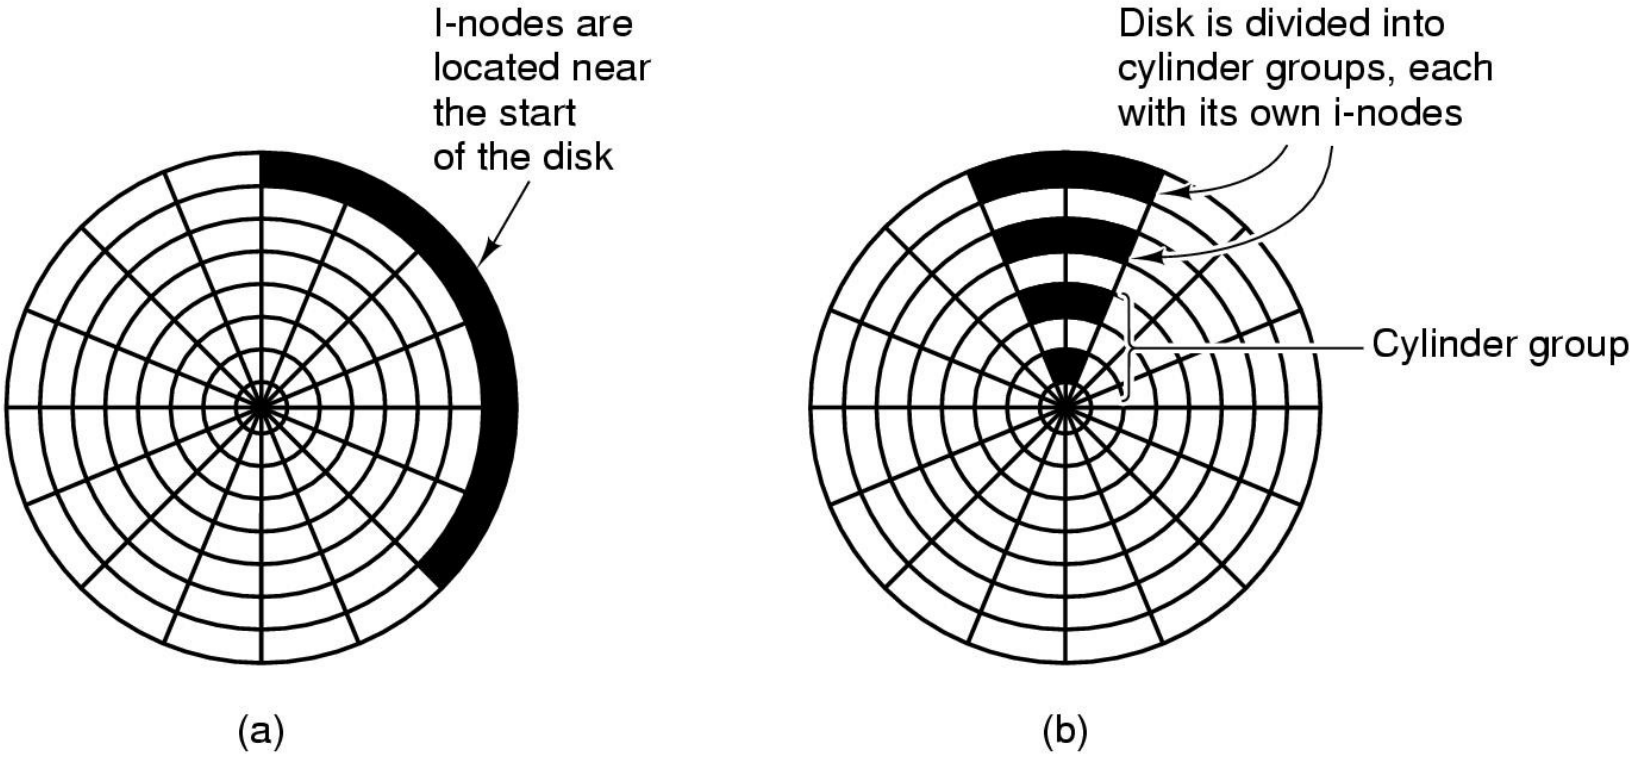

- I-nodes placed at the start of the disk
- Disk divided into cylinder groups
  - each with its own blocks and i-nodes

Fichiers journalisés

- « Log structured file systems »
- La question des lectures est « résolue » via les tampons
- Il faut améliorer les performances des écritures
- Solution de principe : faire de grandes écritures séquentielles

Fichiers journalisés (suite)

- La place des blocs et des i-nodes varie à chaque écriture
- Une table des i-nodes permet l ’accès aléatoire
- Récupération de l ’espace libre : réorganisation de tout le disque

Comparaison

- Performances au niveau des meilleurs systèmes classiques en conditions « dures »
  - Tampons petits
  - Disques occupés à 80 %
- Sont meilleurs dans les autres cas
- Facilitent la récupération après panne

Fiabilité du SGF

- Sauvegardes
- Reconstruction, cohérence des informations
- Restrictions d ’accès
- Sécurité

Les sauvegardes

- Idée : recopier les fichiers sur un autre support jugé plus sûr
- Disque miroir, disques raid
- Sur un support « permanent » (CD)
- Sauvegardes
  - Périodiques
  - Incrémentales
  - Journalisées

Redondance des informations

- Principe : les informations sur disque sont redondantes et permettent de reconstruire des tables détruites
- Reconstruction de la carte des blocs libres
- Reconstruction des catalogues et des i-nodes

Restrictions d'accès

- Utilisateurs et groupes
- Listes de contrôle d'accès
- Verrouillage
- Contrôle « lecteurs-rédacteurs »

Sécurité

- Ordinateur isolé : pas de grave problème
- Ordinateur connecté à un réseau
  - Authentification des utilisateurs
  - Les mots de passe
  - Carte à puce

Les fichiers de PedagOS

- Structures sur disque
- Structures de données en mémoire centrale
- Programmation d'appels systèmes
  - fixer position
  - lecture
  - ouverture

Organisation du disque : descripteurs et blocs

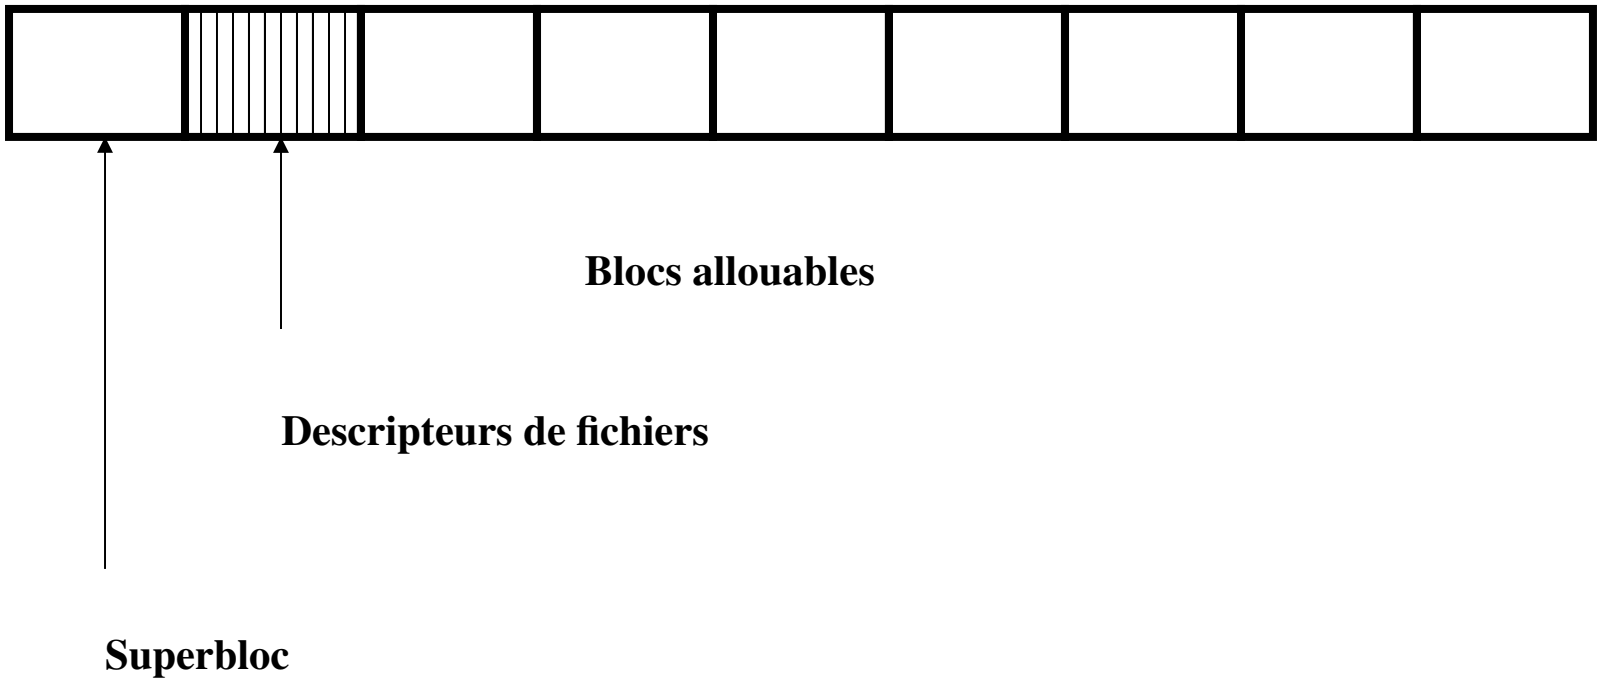

Descripteurs de fichiers

```
struct df {
        nature  ;          // fichier ou catalogue
        taille_phy  ;      //taille physique en octets
        taille_log  ;      // déplacement du dernier caractère écrit
        blocs [NBLOCS]  ;  //numéros des blocs
        bloc_indirect  ;       //numéro du bloc d'indirection simple
        }
```

Accès au disque : cache

- Table gérée en adressage dispersé pour la recherche rapide
- Liste LRU pour le remplacement
- Utilisation via les procédures obtenir_bloc et liberer_bloc

Structures en mémoire centrale

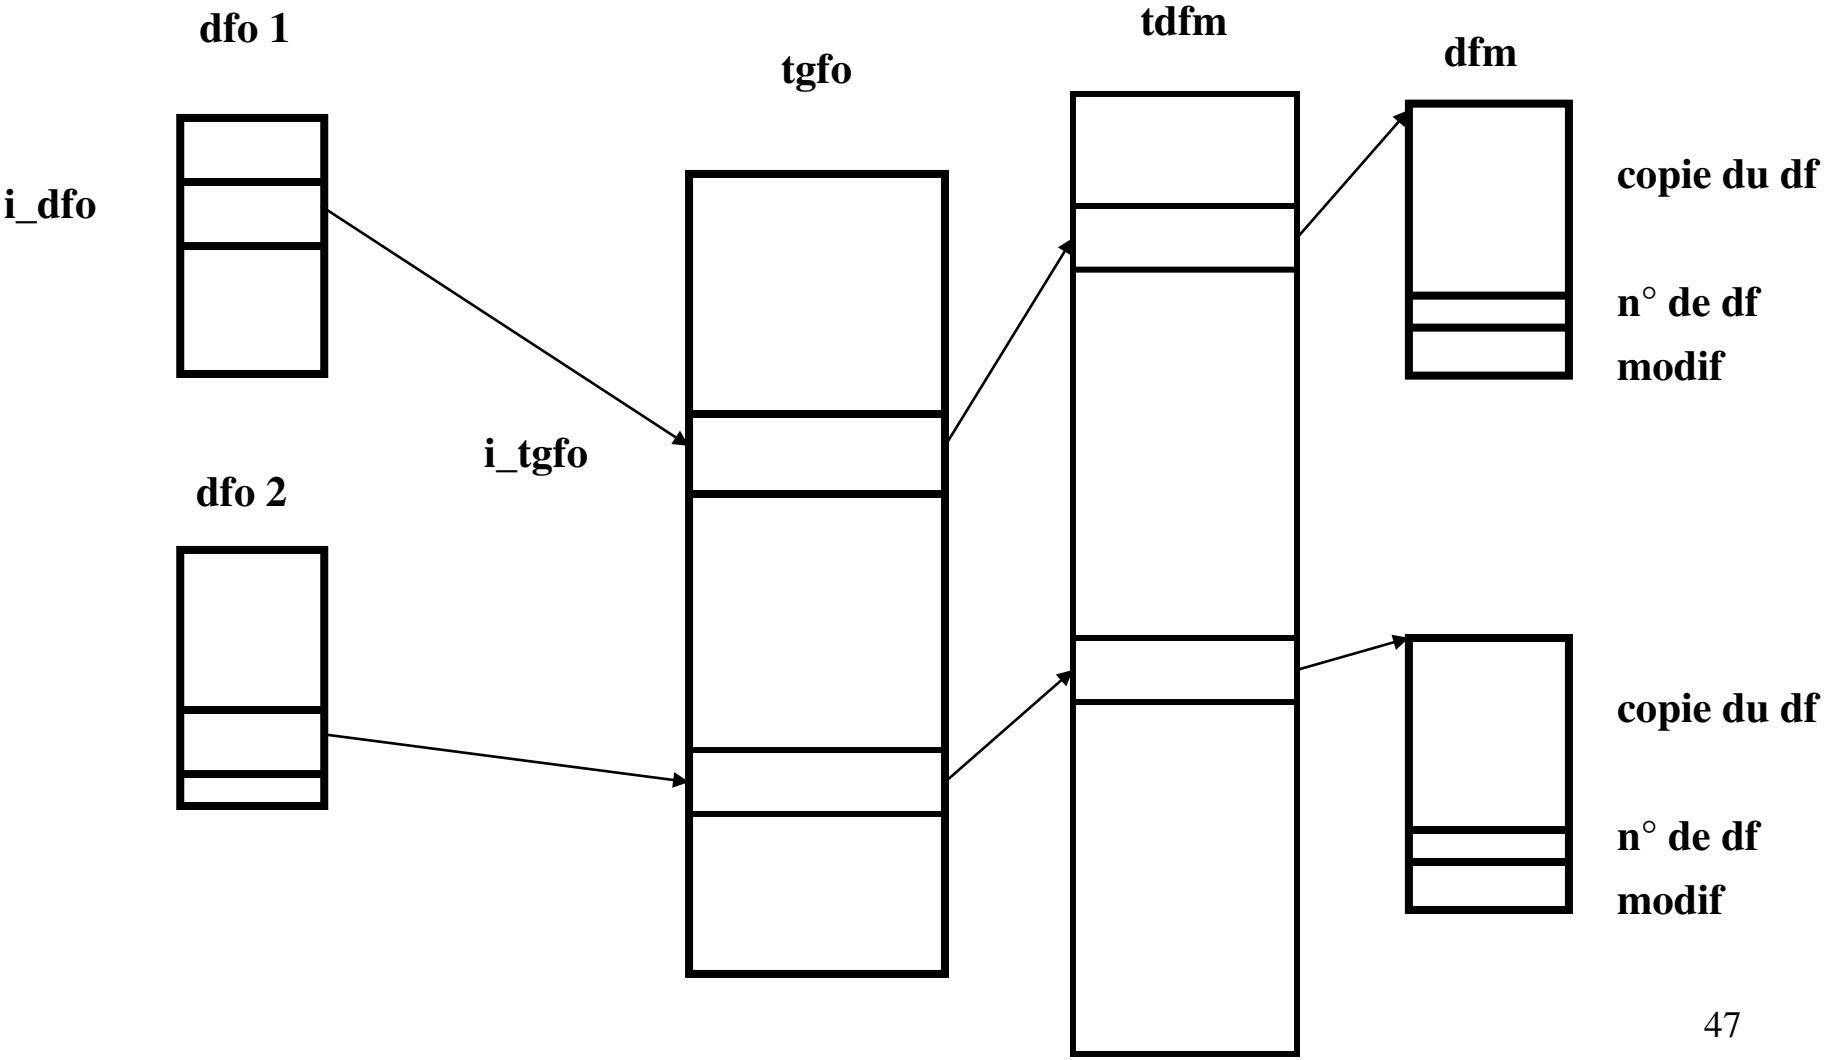

Descripteur de fichier en mémoire

```
struct dfm {
    // copie en mémoire de df
    nature  ;
    taille_phy  ;
    taille_log  ;
    blocs[NBLOCS]  ;
    bloc_indirect  ;
    // champs supplémentaires
    i_df  ;          // numéro du df sur disque
    cpt  ;           // nombre d'utilisateurs du dfm
    etat  ;          // df intact ou modifié depuis la création du dfm
    }
```

Table des fichiers ouverts

- Conserve le mode d'ouverture et la position de chaque fichier ouvert

```
struct entree_tgfo {
      cpt  ;            // compteur des ouvertures en cours
      mode  ;   // mode d'ouverture
      position  ;       // position courante
      i_tdfm  ; // localisation du descripteur de fichier en mémoire
 }
```

Descripteur local à un processus

- Permet une désignation interne à un processus
- Utilisée pour les redirections des E/S standards

Appel système fixer_position

```
exec_fixer_position(i_dfo,position) {
   if ((i_dfo < 0) ll (i_dfo >= MAX_FO_PROC))
      return (-1)  ; // mauvaise valeur d'i_dfo
   if ( proelu->dfo [i_dfo] < 0) return (-1)  ; // fichier non ouvert
   i_tgfo = proelu->dfo [i_dfo]  ;  // indice du fichier dans la tgfo
   dfm= tdfm [tgfo[i_tgfo]->i_tdfm ] ; // pointeur vers le dfm
   if ((position > dfm->taille_log) ll (position <0))
      return (-3)  ; //  nouvelle position invalide
   tgfo[i_tgfo]->position = position  ; // nouvelle position dans la tgfo
   return (0)  ;   // appel système réussi
   }
```

Appel système de lecture

```
exec_lire(i_dfo,adr_mem,nbcar) {
    vérifier paramètres
    récupérer dfm
    position = (ibloc,depl)
    adr_disque = logique_physique (dfm,ibloc)
    obtenir_bloc(adr-disque)
    copie du bloc vers zone utilisateur
    libérer_bloc }
```

Appel système d'ouverture

- Entrée : nom, mode
- Sortie : numéro de dfo
- Effet de bord :mise à jour des tables de fichiers ouverts et de descripteurs en mémoire

Recherche dans les catalogues

Nom de fichier aaa/bbb/ccc

Numéro i_df de descripteur de fichier (catalogue de recherche)

Recherche de aaa ds le catalogue i_df, si cette recherche réussit, on obtient un nouvel i_df dans lequel on va rechercher bbb

A la fin du nom, on a le descripteur recherché

Ouverture (sans détection d'erreurs)

```
exec_ouvrir (nom,mode) {
        indice_df =recherche_arbre(nom,i_df)  ;
        //on va maintenant construire les différentes tables décrivant le fichier
        i_tgfo = allouer_tgfo()  ; // recherche emplacement dans tgfo
        i_dfo = allouer_dfo(proelu->dfo)  ;
        proelu->dfo[i_dfo] = i_tgfo  ;
        tgfo[i_tgfo]->cpt = 1  ;
        tgfo[i_tgfo]->mode = mode  ;
        tgfo[i_tgfo]->position = 0  ; // début du fichier
        i_tdfm = obtenir_dfm(indice_df)  ; //construction du dfm
        ++tdfm[i_tdfm]->cpt  ; // augmentation compteur d'utilisation
        tgfo[i_tgfo]->i_tdfm = i_tdfm  ;
        return(i_dfo)  ;
        }
```

Programmation du cache

- Version 1 : un bloc est écrit sur disque à la récupération (cache « paresseux »)
- Version 2 : vidages anticipés

Recherche d'un bloc

- Grand nombre de blocs
  - Recherche séquentielle inadaptée
- Utilisation d'une table auxiliaire
  - Adressage dispersé (« hash code »)

Descripteur de bloc en mémoire

```
uct dbm {
        cpt ;                   //nombre d'utilisateurs du bloc
        ad_disque ;             // adresse du bloc sur disque
        ad_mem ;                // adresse du bloc en mémoire ce
        etat ;                  // défini plus loin
        liens ;                 // chaînage dans une liste LRU
        }
```

Cache paresseux - états des blocs

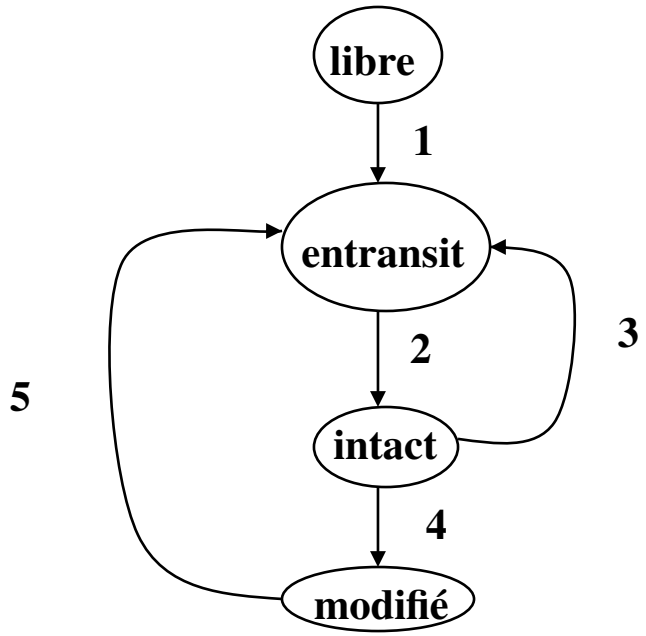

1 allocation d'un bloc libre

2 fin de chargement d'un bloc

3 réallocation d'un bloc intact

4 écriture dans un bloc intact

5 réallocation d'un bloc modifié

Obtenir_bloc (bloc en cache)

```
obtenir_bloc (bd) {
        dbm = recherche_en_cache (bd) ;
        if (dbm != NULL) {  // le bloc est dans le cache
                                //ou en cours de transfert
             if (dbm->etat == entransit) {
            /* le processus est bloqué et son pid placé
            dans la liste des processus en attente du bloc */
            dbm->cpt++ ;
            lancer_processus_suivant ;
            } ;
        dbm->cpt ++ ; chaîner dbm en tête de liste LRU ;
        }
```

Obtenir_bloc (bloc absent)

```
dbm = trouve_place_cache ;
        if (dbm->etat != libre) oter_htable(dbm->ad_disque) ; /* on retire le bloc
                if (dbm->etat == modifié)  { vidage = vrai ;
                copier (dbm, dbm_aux) ;} ;
                dbm->cpt = 1 ;    //mise à jour dbm pour le nouveau bloc
                dbm->etat = entransit ;
                dbm->ad_disque = bd ;
                ajouter_htable (bd,dbm) ;
                chaîner dbm en tête de liste LRU ;
                if (vidage) lancer_vidage (dbm_aux);  // les opérations de vidage
                lancer_chargement (dbm) ;// et chargement sont bloquantes
                dbm->etat = intact ;
                rendre éligibles les processus en attente du bloc ;
                }
        }
```

Cache avec anticipation

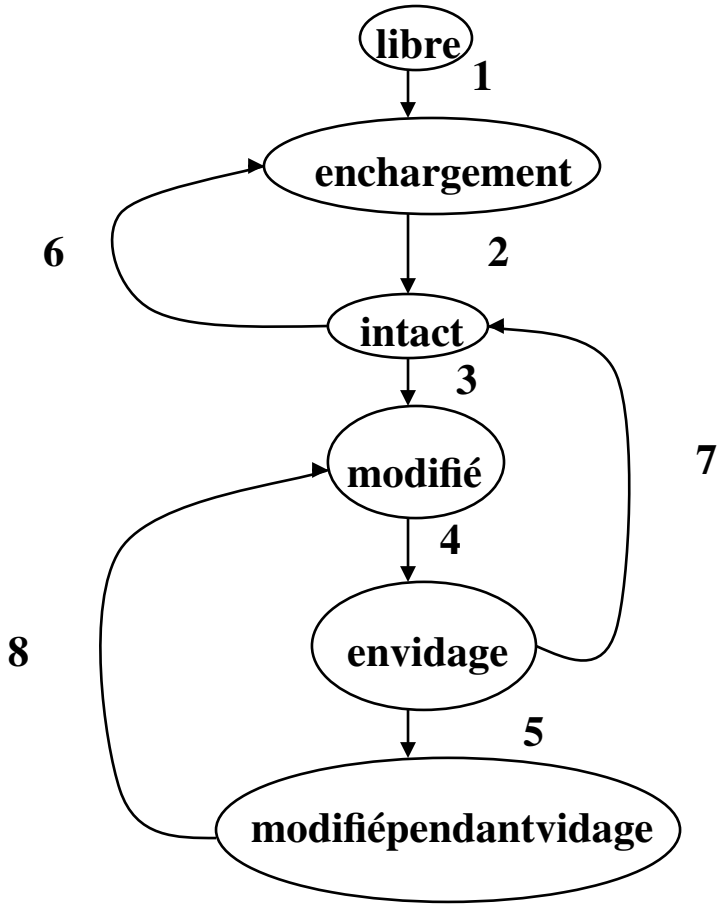

1 allocation d'un bloc libre
2 fin de chargement
3 écriture dans un bloc intact
4 lancement d'un vidage
5 écriture dans un bloc en vidage
6 réallocation d'un bloc
7 fin de vidage
8 fin de vidage d'un bloc remodifié

Vidage anticipé

- Vidage demandé par un processus spécialisé
- Le processus « bouche trou » peut être utilisé
- Si le système est chargé, ce n'est pas suffisant
- Le processus videur est activé périodiquement

Les disques SSD

- Solid State Drive
- Constitués de mémoire flash
  - MLC/SLC : lent/rapide, moins sur
- Performances
  - Accès < 0.1 ms (10 à 100 fois plus rapide)
  - Débit le plus défavorable meilleur que le plus favorable des disques durs (souvent facteur 10)
- Plus coûteux à capacité égale

Les disques SSD (2)

- Mémoire composée de cellules
  - Ne peuvent être écrites qu'un nombre fini de fois (1000 à 100000)
- Ré-écriture coûteuse
  - Nécessité d'effacer une cellule avant de pouvoir écrire dessus
  - Si cellule non vide, une écriture=2 opérations
  - Intérêt d'en avoir toujours des vides
- Effacement fait par le système périodiquement
  - Commande TRIM du disque

Wear leveling

- Répartir les écritures équitablement entre les cellules
  - Pour ne pas que certaines lachent avant d'autres
- Typiquement fait au niveau du contrôleur du disque
  - Mais les FS du type « log » ont un comportement favorable par défaut

Write amplification

- Du au fait que l'effacement se fait sur des paquets de blocs
  - Grain effacement > grain d'écriture
- Récupérer de la place sur un paquet non complètement utilisé =
  1. Déplacer la partie utilisée
  2. Effacer le bloc
  3. Lui réécrire des données

Write amplification (2)

- Provoque des mouvements et écritures supplémentaires
  - Facteur = write amplification
  - Plus le disque est plein plus il est élevé
- Contrôle par overprovisioning
  - Réserver des blocs en diminuant la capacité utilisable du disque
  - Avoir toujours des blocs libres