

Statistique Inférentielle Avancée

Durée : 3 heures.

Tous documents autorisés.

Les deux parties sont indépendantes.

Les résultats vus en cours ou en TD n'ont pas à être redémontrés.

Barème indicatif - Partie 1 : 12 pts, Partie 2 : 8 pts.

Première partie

Soit $\theta \in \mathbb{N}^*$. Une variable aléatoire X est de loi uniforme (discrète) sur $\{1, \dots, \theta\}$ si elle est à valeurs dans $\{1, \dots, \theta\}$ et que

$$P(X = k) = \frac{1}{\theta} \mathbb{1}_{\{1, \dots, \theta\}}(k).$$

1. Donner la fonction de répartition et l'espérance mathématique de X .
2. Soient X_1, \dots, X_n n variables aléatoires indépendantes et de même loi uniforme sur $\{1, \dots, \theta\}$. Soit $T = X_n^*$. Donner la fonction de répartition de T et les probabilités élémentaires $P(T = t) = P(T \leq t) - P(T \leq t - 1)$, $\forall t \in \{1, \dots, \theta\}$.
3. Montrer que $\forall i \in \{1, \dots, n\}$, $\forall t \in \{1, \dots, \theta\}$, la loi de probabilité conditionnelle de X_i sachant $[T = t]$ est donnée par :

$$P(X_i = k | T = t) = \begin{cases} \frac{t^{n-1} - (t-1)^{n-1}}{t^n - (t-1)^n} & \text{si } k \in \{1, \dots, t-1\} \\ \frac{t^{n-1}}{t^n - (t-1)^n} & \text{si } k = t \\ 0 & \text{sinon} \end{cases}$$

4. Un récipient contient un nombre inconnu θ d'objets identiques numérotés de 1 à θ , que l'on désire estimer. Pour cela, on effectue n tirages au hasard dans le récipient. Après chaque tirage, on note le numéro de l'objet obtenu et on remet celui-ci dans le récipient. Quel est le modèle statistique associé au résultat x_1, \dots, x_n de cette expérience ?
5. Ecrire la fonction de vraisemblance de ce modèle paramétrique et calculer l'estimateur de maximum de vraisemblance de θ . Montrer sans calculs qu'il est biaisé.
6. Montrer que la statistique de maximum de vraisemblance est exhaustive et complète.

7. Calculer l'estimateur de θ par la méthode des moments. Montrer qu'il est sans biais.
8. En déduire explicitement l'estimateur sans biais et de variance minimale de θ . Quel est son inconvénient et comment y remédier ?
9. Pour $n = 20$, estimer θ quand $t = 10$, $t = 40$ et $t = 100$.

Deuxième partie

Soient X_1, \dots, X_n n variables aléatoires réelles indépendantes et de même loi, de variance $Var(X) = \mu_2$, de fonction de répartition F et telle que $E[X^4] < \infty$. On a vu en cours que :

$$\sqrt{n} \frac{S'_n{}^2 - \mu_2}{\sqrt{\mu_4 - \mu_2^2}} \xrightarrow{\mathcal{L}} \mathcal{N}(0, 1),$$

ce qui permet de montrer qu'un intervalle de confiance asymptotique de seuil α pour μ_2 est :

$$\left[S'_n{}^2 - \frac{u_\alpha}{\sqrt{n}} \sqrt{\mu_4^e - S'_n{}^4}, S'_n{}^2 + \frac{u_\alpha}{\sqrt{n}} \sqrt{\mu_4^e - S'_n{}^4} \right].$$

Quand n est trop petit, il est possible que la borne inférieure de cet intervalle soit négative, ce qui pose problème puisque la quantité à estimer, la variance, est positive. Pour résoudre ce problème, on utilise la variante de la méthode delta suivante.

Si $\{Y_n\}_{n \geq 1}$ est une suite de variables aléatoires réelles telle que

$$\sqrt{n} (Y_n - \theta) \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2),$$

alors pour toute fonction dérivable φ , on a

$$\sqrt{n} [\varphi(Y_n) - \varphi(\theta)] \xrightarrow{\mathcal{L}} \mathcal{N}(0, \sigma^2 \varphi'(\theta)^2).$$

1. Déterminez la loi asymptotique de $\sqrt{n} (\ln S'_n{}^2 - \ln \mu_2)$.
2. Montrer que $\frac{S'_n{}^2}{\sqrt{\mu_4^e - S'_n{}^4}}$ converge en probabilité vers $\frac{\mu_2}{\sqrt{\mu_4 - \mu_2^2}}$.
3. En utilisant les 2 résultats précédents et le théorème de Slutsky, donnez un nouvel intervalle de confiance asymptotique de seuil α pour μ_2 , dont la borne inférieure est toujours positive.
4. De même, un intervalle de confiance asymptotique de seuil α pour $F(x)$ est

$$\left[\mathbb{F}_n(x) - \frac{u_\alpha}{\sqrt{n}} \sqrt{\mathbb{F}_n(x)(1 - \mathbb{F}_n(x))}, \mathbb{F}_n(x) + \frac{u_\alpha}{\sqrt{n}} \sqrt{\mathbb{F}_n(x)(1 - \mathbb{F}_n(x))} \right]$$

Il peut arriver que la borne inférieure de cet intervalle soit négative et que la borne supérieure soit supérieure à 1.

En utilisant la méthode delta avec la fonction logit $\varphi(p) = \ln \frac{p}{1-p}$, construire un nouvel intervalle de confiance asymptotique de seuil α pour $F(x)$. Montrer que les bornes de cet intervalle sont forcément comprises entre 0 et 1.